

# Технический отчёт

## Предсказание LTV пользователей

Хакатон по машинному обучению

---

**Задача:** Предсказание суммарного GMV пользователей за 30 дней  
на основе обезличенных данных активности в Поиске и Каталоге

---

|               |                                              |
|---------------|----------------------------------------------|
| Участник:     | Кирилл Егоров                                |
| Метрика:      | RMSLE (Root Mean Squared Log Error)          |
| Tie-breaker:  | Gini по предсказаниям + RMSPE суммарного GMV |
| Данные:       | 250 000 пользователей, 01.01.2025–13.02.2026 |
| Текущий ЛБ:   | <b>1.66049</b> (CatBoost v4a Baseline)       |
| Публичный ЛБ: | 20% (50 000 клиентов)                        |
| Приватный ЛБ: | 80% (200 000 клиентов)                       |
| Старт:        | 10 августа 2026 г.                           |
| Дедлайн:      | ≈ 31 августа 2026 г.                         |
| Лимит:        | 5 сабмитов / день, 2 финальных решения       |
| GPU:          | NVIDIA RTX 4050 Laptop (6 ГБ VRAM)           |

# Содержание

---

|          |                                                       |          |
|----------|-------------------------------------------------------|----------|
| <b>1</b> | <b>Описание задачи и данных</b>                       | <b>1</b> |
| 1.1      | Постановка задачи . . . . .                           | 1        |
| 1.2      | Особенности исходных данных . . . . .                 | 1        |
| <b>2</b> | <b>Схема валидации: Walk-Forward Cross-Validation</b> | <b>1</b> |
| <b>3</b> | <b>История экспериментов: Итерации v1 — v3</b>        | <b>1</b> |
| <b>4</b> | <b>Альтернативные подходы: BTYD и Two-Stage</b>       | <b>2</b> |
| 4.1      | BTYD (BG/NBD + Gamma-Gamma) . . . . .                 | 2        |
| 4.2      | Two-Stage Model . . . . .                             | 2        |
| <b>5</b> | <b>Итерация v4: Прорыв (Текущий чемпион)</b>          | <b>3</b> |
| 5.1      | Философия признакового пространства v4 . . . . .      | 3        |
| 5.2      | CatBoost v4a Baseline . . . . .                       | 3        |
| <b>6</b> | <b>Стратегия финальных ансамблей (5 сабмитов)</b>     | <b>4</b> |
|          | <b>Приложение: Ключевые формулы</b>                   | <b>4</b> |

## 1. Описание задачи и данных

### 1.1. Постановка задачи

Задача — предсказание **Customer Lifetime Value (LTV)** на горизонте 30 дней. Модель должна по истории активности пользователя предсказать суммарный GMV за период с 14.02.2026 по 15.03.2026.

**Публичный / Приватный лидерборд: 20% / 80%!**

Оценка на публичном лидерборде вычисляется только по 50 000 из 250 000 клиентов. Это означает высокий риск *public-private shake-up*.

**Метрика качества:**

$$\text{RMSLE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (\log(1 + \hat{y}_i) - \log(1 + y_i))^2}$$

### 1.2. Особенности исходных данных

**Объём:** 30+ млн записей, 250 000 клиентов

**Период:** 01.01.2025 – 13.02.2026 (407 дней)

**Тип:** Прореженные временные ряды (спарс).

Особенности целевой переменной: данные сильно **zero-inflated**. Около 45.1% пользователей в обучающей выборке не совершают ни одной покупки ( $\text{target} = 0$ ).

## 2. Схема валидации: Walk-Forward Cross-Validation

Для временных рядов используется строго **Walk-Forward CV**. Тестировались два подхода к формированию обучающей выборки:

1. **Single-Fold:** обучение только на предыдущем фолде ( $\mathcal{D}_{val-1} \rightarrow \mathcal{D}_{val}$ ). Подход показал наилучшую устойчивость.
2. **Cumulative:** обучение на всех исторических фолдах ( $\bigcup_{j=0}^{val-1} \mathcal{D}_j \rightarrow \mathcal{D}_{val}$ ).

Параметр **stride** (шаг смещения anchor date) критически влияет на качество. При  $\text{stride} = 7$  и  $\text{target} = 30$  возникало 77%-е перекрытие таргетов между фолдами, что приводило к сильному переобучению алгоритмов (в частности, Optuna). Оптимальным решением признан  $\text{stride} = 14$ .

## 3. История экспериментов: Итерации v1 — v3

В процессе разработки пайплайн прошёл через 3 крупные итерации, выявившие ключевые проблемы данных:

Таблица 1: Ретроспектива итераций v1 – v3

| Версия | Достижения и проблемы                                                                       | Лучший RMSLE |
|--------|---------------------------------------------------------------------------------------------|--------------|
| v1     | Baseline CatBoost на 60 фичах. Stride=7.                                                    | 1.6703       |
| v2     | Увеличение до 440 фичей. Утечка данных из-за stride=7 сломала подбор параметров Optuna.     | 1.6880       |
| v3     | Исправлен stride=30 (нет перекрытия). Внедрён LightGBM и Feature Selection (топ-150 фичей). | 1.6711       |

**Проблема мультиколлинеарности моделей в v3:**

Анализ ансамбля показал, что предсказания CatBoost v3 и LightGBM v3 имеют корреляцию Пирсона 0.9927 — фактически они полностью идентичны. Единственный ортогональный сигнал давала модель RNN ( $\rho \approx 0.93$ ).

## 4. Альтернативные подходы: BTYD и Two-Stage

Для решения проблемы завышенных нулей (zero-inflation) были реализованы специализированные подходы.

### 4.1. BTYD (BG/NBD + Gamma-Gamma)

Классическая вероятностная модель поведения покупателей (ноутбук 7\_btyd.ipynb). Модель BG/NBD оценивала частоту покупок и вероятность оттока  $P(\text{alive})$ , а Gamma-Gamma — средний чек. **Результат:** Модель сильно зависила ожидания. Средний предсказанный LTV составил 85.17, что критически оторвано от реальности лучших ML-моделей (средний предикт  $\approx 35.35$ ). Отправка чистого сабмита признана нецелесообразной.

### 4.2. Two-Stage Model

Двухэтапная архитектура (ноутбук 6\_two\_stage.ipynb):

- **Stage 1:** CatBoostClassifier предсказывает  $P(GMV > 0)$ .
- **Stage 2:** CatBoostRegressor обучается *только* на покупателях ( $E[GMV|buy]$ ).

**Результат:** Как самостоятельная модель Two-Stage проиграла бейзлайну (лучший RMSLE: 1.90800). Однако **Stage 1 классификатор дал важнейший инсайт:** анализ показал, что оптимальный порог вероятности покупки составляет  $P(buy) = 0.46$ .

**Метод «Zero-Hack»:**

Предсказания  $P(buy)$  из классификатора можно использовать как маску для лучших регрессоров. Зануление предиктов пользователей с  $P(buy) < 0.46$  локально улучшило RMSLE модели Two-Stage с 2.04 до 1.90. Этот хак будет применён к финальному ансамблю.

## 5. Итерация v4: Прорыв (Текущий чемпион)

Возврат к принципам надежного бейзлайна, но с расширенными горизонтами данных (ноутбук 8\_data\_v4\_2.ipynb).

### 5.1. Философия признакового пространства v4

1. **Окна полной истории:** добавлены агрегации за 270d и 365d.
2. **Новые срезы:** `gmw_search`, `gmw_cat`, флаги `search/cat`.
3. **RFM-метрики:** добавлены frequency (`freq_cart`, `active_days`) и recency (`recency_cart`, `user_age_days`).
4. **Схема валидации:** возврат к `stride = 14` (золотая середина) и **Single-Fold** обучению.

### 5.2. CatBoost v4a Baseline

Схема Single-Fold (без переобучающего cumulative-накопления) на новых 392 фичах выдала рекордный результат. Модель самостоятельно отбирала признаки без принудительного Feature Selection.

**Результат CatBoost v4a на Лидерборде: 1.66049**

Это лучший результат за весь цикл хакатона, приблизивший решение к лидеру платформы (1,6461846817).

Таблица 2: Топ-10 признаков (CatBoost v4a)

| #  | Признак                          | Важность, % |
|----|----------------------------------|-------------|
| 1  | <code>recency_ord_days</code>    | 1.33%       |
| 2  | <code>freq_ord_365d</code>       | 1.33%       |
| 3  | <code>user_age_days</code>       | 1.29%       |
| 4  | <code>to_ord_sum_365d</code>     | 1.22%       |
| 5  | <code>freq_ord_270d</code>       | 1.21%       |
| 6  | <code>freq_ord_90d</code>        | 1.18%       |
| 7  | <code>trend_gmw_90d_365d</code>  | 1.11%       |
| 8  | <code>gmw_search_sum_365d</code> | 0.96%       |
| 9  | <code>freq_ord_180d</code>       | 0.92%       |
| 10 | <code>recency_cat_days</code>    | 0.88%       |

Анализ важности показал абсолютное доминирование долгосрочных агрегатов (365d, 270d) и метрик недавности (recency).

## 6. Стратегия финальных ансамблей (5 сабмитов)

Учитывая доступный лимит в 5 отправок, стратегия построена на использовании чемпиона **CatBoost v4a** в качестве базы. Внутривидовые бленды (Single + Cumulative) отменены из-за идентичности датасетов при  $N\_FOLDS = 2$ .

**Файлы для загрузки на Лидерборд:**

1. **Ортогональный бленд v1:** 85% CatBoost v4a + 15% RNN v2.  
Нейросеть сгладит редкие выбросы бустинга благодаря своей ортогональности.
2. **Ортогональный бленд v2:** 90% CatBoost v4a + 10% RNN v2.
3. **Zero-Hack Champion:** Чистый предикт CatBoost v4a, в котором принудительно установлены нули для пользователей с  $P(buy) < 0.46$  (маска от классификатора).
4. **LightGBM v4 (Соло):** Модель LightGBM, обученная на новых мощных признаках v4.
5. **Мощный Бустинг-Бленд:** 60% CatBoost v4a + 40% LightGBM v4.  
Диверсификация за счёт комбинации алгоритмов level-wise и leaf-wise сплита.

## Приложение: Ключевые формулы

Оценка качества (RMSLE)

$$\text{RMSLE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (\log(1 + \hat{y}_i) - \log(1 + y_i))^2}$$

Log-трансформация

$$\tilde{y} = \log(1 + \max(y, 0)), \quad \hat{y} = \max(e^{\tilde{y}} - 1, 0)$$

Tie-breaker: Gini Normalized

$$G_{\text{norm}} = \frac{G(\hat{y}, y)}{G(y, y)} \quad G(a, b) = \frac{1}{n} \left( \frac{\sum_i b_{[a_i \downarrow]} \cdot i}{\sum_i b_i} - \frac{n+1}{2} \right)$$