

Технический отчёт

Предсказание LTV пользователей

Хакатон по машинному обучению

Задача: Предсказание суммарного GMV пользователей за 30 дней
на основе обезличенных данных активности в Поиске и Каталоге

Участник: Кирилл Егоров

Метрика: RMSLE (Root Mean Squared Log Error)

Данные: 250 000 пользователей, 01.01.2025–13.02.2026

Public LB: **1.65298** ($\text{Blend} \times 1.12375$)^{1.005}

Private LB: **1.66836** (112 место)

GPU: NVIDIA RTX 4050 Laptop (6 ГБ VRAM)

Содержание

1	Теоретический базис и математическая модель	1
1.1	Нейросетевая модель: Tabular MLP и ZILN	1
1.2	Градиентный бустинг: CatBoost и XGBoost	1
2	Архитектура решения и инженерия признаков	2
2.1	Схема валидации и алгоритмы стабилизации	2
2.2	Конвейер генерации признаков (Feature Engineering)	2
3	Успешные исследования и тестирование гипотез	2
4	Анализ отвергнутых гипотез	3
5	Валидация пайплайна и результаты	4

1. Теоретический базис и математическая модель

Оценка качества предсказаний Customer Lifetime Value (LTV) производится с помощью логарифмической метрики Root Mean Squared Logarithmic Error (RMSLE). Фундаментальная сложность заключается в смешанном (Zero-Inflated) распределении целевой переменной: порядка 46.4% пользователей в выборке не совершают ни одной транзакции в прогнозном окне (`target = 0`) [2].

1.1. Нейросетевая модель: Tabular MLP и ZILN

Для корректного моделирования нулевых и положительных трат была разработана вероятностная архитектура с применением функции потерь **Zero-Inflated LogNormal (ZILN)**. Сеть аппроксимирует три логита $\mathbf{z} = (z_0, z_1, z_2)$, которые трансформируются в параметры распределения [2]:

$$p = \frac{1}{1 + \exp(-z_0)}, \quad \mu = z_1, \quad \sigma = \log(1 + \exp(z_2))$$

Итоговая функция потерь объединяет бинарную кросс-энтропию (BCE) и негативное логарифмическое правдоподобие (NLL) [4, 2]:

$$\mathcal{L} = -\mathbb{I}_{y=0} \log(1 - p) - \mathbb{I}_{y>0} \left[\log(p) - \frac{\log(\sigma\sqrt{2\pi}) + (\log y - \mu)^2}{2\sigma^2} \right]$$

Для извлечения финального предсказания применена эмпирически выведенная формула, напрямую минимизирующая логарифмический штраф метрики хакатона [2]:

$$\hat{y} = \exp(p \cdot \mu) - 1$$

1.2. Градиентный бустинг: CatBoost и XGBoost

Обе древовидные модели оптимизировались под метрику RMSE на предварительно логарифмированном таргете $\tilde{y}_i = \log(1 + y_i)$ [2].

CatBoost использует симметричные (oblivious) деревья решений, где один и тот же предикат расщепления применяется ко всему уровню дерева [5]. Итоговый прогноз формируется суммированием весов листьев:

$$F(x) = \sum_{k=1}^K c_k \mathbb{I}(x \in R_k)$$

XGBoost строит несимметричные деревья, применяя алгоритм гистограммного поиска сплитов. Применяется строгая оптимизация с L_1 (α) и L_2 (λ) регуляризацией листьев w_k [6, 2]:

$$\mathcal{L}_{\text{XGB}} = \sum_{i=1}^N \frac{1}{2} (\tilde{y}_i - \hat{y}_i)^2 + \sum_{k=1}^K \left(\gamma T_k + \frac{1}{2} \lambda \|w_k\|^2 + \alpha \|w_k\|_1 \right)$$

В пайплайне заданы веса $\alpha = 2.0, \lambda = 5.0$, что жестко штрафует сложные деревья и выявляет скрытые нелинейные паттерны [2].

2. Архитектура решения и инженерия признаков

2.1. Схема валидации и алгоритмы стабилизации

Для исключения эффекта «заглядывания в будущее» реализован алгоритм **Walk-Forward Cross-Validation** [1]. Анкорная дата t_{anchor} последовательно сдвигается на шаг S (14 дней), формируя независимые обучающие и валидационные блоки:

$$\text{Train}_k = \{(x_i, y_i) \mid t_i \in [t_{\text{anchor}}^{(k)} - H, t_{\text{anchor}}^{(k)}]\}$$

$$\text{Val}_k = \{(x_i, y_i) \mid t_i \in [t_{\text{anchor}}^{(k)} + 1, t_{\text{anchor}}^{(k)} + 30]\}$$

где H — глубина исторического окна (180 дней) [1].

Для снижения дисперсии градиентного бустинга применена техника **Seed Averaging**. Итоговый прогноз базовой модели CatBoost $\hat{y}_{\text{CB}}$ формируется как арифметическое среднее предсказаний 5 моделей, обученных с различными седами [2]:

$$\hat{y}_{\text{CB}}(x) = \frac{1}{5} \sum_{m=1}^5 F_m(x; \text{seed}_m)$$

2.2. Конвейер генерации признаков (Feature Engineering)

На базе библиотеки **Polars** реализована генерация 437 признаков [1].

- **Lifecycle Trajectory:** Отношение трат за последовательные периоды позволило вычислить метрики ускорения заказов (`order_acceleration`):

$$\text{Accel} = \frac{\text{Ord}_{w1} + \epsilon}{\text{Ord}_{w2} + \epsilon} - \frac{\text{Ord}_{w3} + \epsilon}{\text{Ord}_{w4} + \epsilon}$$

- **Межпокупочные интервалы (Gaps):** Расчет математического ожидания (`mean_order_gap`) и стандартного отклонения (`std_order_gap`). Коэффициент вариации σ/μ (`order_regularity_cv`) позволил оценивать стабильность спроса. Пустые интервалы заполнялись значением 999.0 [1].
- **Индикация оттока:** Созданы бинарные флаги `is_single_buyer` и `is_dormant`. Последний активируется для пользователей без покупок более 120 дней [1].
- **Винзоризация таргета (Target Capping):** Целевая переменная жестко ограничивалась по 99.9-му перцентилю (4000.0) для защиты градиентов от аномальных «китов» [1].

3. Успешные исследования и тестирование гипотез

1. Опровержение гипотезы отдельных моделей (Two-Stage Pipeline). Обучение отдельного бинарного классификатора и регрессора приводило к перемножению ошибок моделей. Внедрение единой нейросети (Tabular MLP) с функцией ZILN

Loss математически корректно связало вероятности p и μ на уровне градиентов, что дало значительный прирост OOF-метрики [2].

2. Трансформация признакового пространства. Использование `StandardScaler` приводило к коллапсу нейросети из-за выбросов. Переход на `QuantileTransformer` жестко нормализовал все признаки в идеальную гауссиану в границах $[-5.0, 5.0]$, обеспечив стабильную сходимость [2].

3. Выявление сезонного сдвига (Seasonal Concept Drift). Анализ исторических логов показал, что тестовая выборка (14.02 - 15.03) подвержена весенней сезонности. По данным 2025 года конверсия в этот месяц росла с 37.23% до 40.29%, а средний чек с 59.53 до 59.97 [3]. Был рассчитан теоретический мультипликатор 1.0901, который в ходе бинарного поиска был уточнен до эмпирического оптимума 1.12375 [3].

4. Геометрия распределения (Гамма-коррекция). Выявлено, что линейный множитель недооценивает сверхкрупных "китов". Применение нелинейного растяжения хвоста (возведение предсказаний в степень 1.005) поверх линейного множителя позволило сместить крупные чеки по экспоненте, не искажая нули, что привело к абсолютному рекорду 1.65298 на Public LB [3].

4. Анализ отвергнутых гипотез

Опираясь на историю отправок (раздел 5), ряд подходов был классифицирован как математически или алгоритмически неэффективный для текущей задачи:

- **Принудительное зануление микро-шума:** Отсечение прогнозов ниже 1.5 рублей (`v6_champ_zero_noise_1.5.csv`) уронило скор до 1.67025. Это доказало, что RMSLE сверхжестко штрафует за искусственные нули для скрытых покупателей.
- **Кусочные множители (Piecewise Drift):** Разделение аудитории по порогам (мелкие/крупные чеки) и применение к ним разных множителей показало результат хуже базового, подтвердив абсолютную плавность и непрерывность сезонного сдвига на всей выборке.
- **Пороговое масштабирование (Smart Multiplier):** Гипотеза о том, что праздничный рост затронул только лояльных клиентов (пороги 100, 300, 500), не подтвердилась. Ограничение буста только для "китов" ухудшило скор, доказав, что весенний сдвиг равномерно затронул всю аудиторию.
- **Микро-сдвиг базовой вероятности (Offset):** Искусственное добавление константы +0.1 ко всем предсказаниям уронило метрику до 1.65413 из-за начисления логарифмического штрафа за искажение истинных нулей.
- **Вероятностные BTYD-модели (Buy Till You Die):** Классические алгоритмы (BG/NBD) показали неспособность прогнозировать LTV на коротком 30-дневном горизонте ($\text{RMSLE} > 1.76$).
- **Логарифмический блендинг (Log-Space Blending):** Геометрическое усреднение предсказаний слишком сильно пессимизировало прогнозы для крупных покупателей, уступив линейному арифметическому бленду.

5. Валидация пайплайна и результаты

Для финального решения использовался арифметический блендинг предсказаний с весами, оптимизированными для достижения максимальной ортогональности ошибок [2]:

- **CatBoost (70%)**: Стабильный базовый прогноз (OOF RMSLE: 1.66115).
- **Tabular MLP ZILN (20%)**: Сглаживает нулевых покупателей (OOF RMSLE: 1.66912).
- **XGBoost (10%)**: Корректировщик нелинейностей (OOF RMSLE: 1.64183).

Итоговый бленд без масштабирования показал OOF RMSLE 1.65559. Применение сезонного множителя 1.12375 и последующей Гамма-коррекции со степенью 1.005 вывело решение на финальный скор **1.65298** на публичном лидерборде и **1.66836** на скрытом приватном лидерборде [3]. Отсутствие существенного падения (shake-up) между открытой и закрытой выборками доказывает высочайшую стабильность Walk-Forward валидации.

Таблица 1: Часть 1: Чемпионы, тюнинги и проверка гипотез

Имя файла	RMSLE	Примечание
v6_gamma_1.005.csv	1.65298	Абсолютный оптимум (Гамма $y^{1.005}$)
v6_champion_mult_1.12375.csv	1.65305	Оптимум линейного множителя
v6_champ_clipped_4000.csv	1.65306	Идентичный результат (отсутствие выбросов >4000)
v6_champion_mult_1.125.csv	1.65305	Бинарный поиск множителя
v6_champion_mult_1.1225.csv	1.65305	Бинарный поиск множителя
v6_champion_mult_1.12.csv	1.65306	Разведка правой границы
v6_champion_mult_1.13.csv	1.65306	Разведка правой границы
v6_champion_mult_1.14.csv	1.65309	Подтверждение экстремума
v6_piecewise_small_115.csv	1.65313	Кусочный множитель (мелкие чеки)
v6_champion_mult_1.10.csv	1.65313	Приближение к дну
v6_champion_mult_1.09.csv	1.65321	Расчетный сдвиг 2025 года
v6_gamma_0.995.csv	1.65324	Гамма-сжатие ($y^{0.995}$)
v6_piecewise_large_115.csv	1.65340	Кусочный множитель (крупные чеки)
v6_champion_mult_1.05.csv	1.65389	Успешный старт калибровки
v6_champ_offset_0.1.csv	1.65413	Микро-сдвиг базового прогноза (+0.1)
v6_champion_mult_1.03.csv	1.65445	
v6_champion_mult_1.02.csv	1.65479	
v6_smart_mult_th_100.csv	1.65535	Пороговое умножение (от 100)
v6_arithmetic_cb70_mlp20_xgb10	1.65559	Лучший чистый базовый ансамбль
v6_arithmetic_cb65_mlp25_xgb10	1.65566	Тест увеличенной доли MLP
v6_arithmetic_cb65_mlp20_xgb15	1.65568	Тест увеличенной доли XGBoost
v6_smart_mult_th_500.csv	1.65573	Пороговое умножение (от 500)
v6_arithmetic_cb75_mlp15_xgb10	1.65574	
v6_smart_mult_th_300.csv	1.65575	Пороговое умножение (от 300)

Таблица 2: Часть 2: Поиск базового ансамбля и эксперименты (25–46)

Имя файла	RMSLE	Примечание
arithmetic_cb75_mlp15_xgb10.csv	1.65581	
arithmetic_cb75_mlp20_xgb05.csv	1.65584	
FINAL_blend_cb80_mlp15_xgb05	1.65590	
arithmetic_cb85_mlp10_xgb05.csv	1.65601	
FINAL_blend_cb85_mlp15.csv	1.65605	
v6_champion_mult_0.98.csv	1.65655	Ухудшение (занижение прогноза)
catboost_v5_seed_avg.csv	1.65656	
catboost_v6_seed_avg.csv	1.65678	Соло CatBoost (v6)
v6_champion_mult_0.97.csv	1.65710	
blend_seed_avg_92_rnn8.csv	1.65878	Бывший лидер (v4b + RNN)
blend_seed_avg_90_rnn10.csv	1.65884	
blend_seed_avg_95_rnn5.csv	1.65890	
frank_cb70_ziln20_xgb5_rnn5.csv	1.65912	
frank_cb75_ziln20_rnn5.csv	1.65912	
blend_pseudo_90_rnn10.csv	1.65929	Эксперимент с pseudo-labeling
blend_ortho_90_10.csv	1.65935	
logblend_cb800_mlp150_xgb50.csv	1.65975	Отказ от Log-Space блендинга
frank_cb70_ziln15_rnn15.csv	1.65977	
catboost_v4a_seed_avg.csv	1.65984	
blend_ortho_85_15.csv	1.65992	
ziln_v6_v1_submission.csv	1.66008	Рекорд соло-нейросети ZILN (v6)
catboost_v4a_baseline_sub...	1.66049	

Таблица 3: Часть 3: Ранние версии, утечки и бейзлайны (47–73)

Имя файла	RMSLE	Примечание
blend_v4a_ortho_95_05.csv	1.66071	
blend_v4a_ortho_90_10.csv	1.66113	
ziln_v5_v1_submission.csv	1.66220	
catboost_v5_seed_avg.csv	1.66265	Оверфит Optuna
blend_v4a60_lgbm40.csv	1.66336	
xgboost_v6_submission.csv	1.66478	Соло XGBoost (v6)
xgboost_v5_submission.csv	1.66506	
mlp_ziln_submission.csv	1.66545	
v6_champ_zero_noise_1.5.csv	1.67025	Провал гипотезы принудительного за- нуления микро-прогнозов
catboost_baseline_submission	1.67028	Baseline от организаторов
xgboost_log_submission.csv	1.67102	
lgbm_v3_submission.csv	1.67115	
catboost_v3_submission.csv	1.67116	
catboost_v4_cumul_sub...	1.67126	
catboost_v4_single_sub...	1.67177	
blend_cbv3_80_rnnv3_19.csv	1.67380	
blend_cbv3_70_rnnv3_30.csv	1.67583	
ensemble_cb70_rnn30.csv	1.67588	
blend_cbv3_65_rnnv3_35.csv	1.67702	
lgbm_v4_submission.csv	1.68433	Нестабильность LightGBM
ensemble_v2_cb70_rnn30.csv	1.68803	Утечка данных в v2
ensemble_v2_cb60_rnn40.csv	1.68942	Утечка данных в v2
catboost_v2_submission.csv	1.69009	Утечка данных в v2
lgbm_v4_submission.csv	1.70118	
rnn_v4_submission.csv	1.70489	Соло RNN (v4)
rnn_v2_submission.csv	1.71792	
catboost_v4a_zero_hacked	1.73573	Провал гипотезы жестких нулей
rnn_baseline_submission.csv	1.73624	
btyd_blend_btyd2_cb8.csv	1.76655	Провал вероятностной модели BTYD
catboost_tuned_submission	1.79400	Провал поиска параметров Optuna v1
btyd_blend_btyd3_cb7.csv	1.81827	
rnn_v4_submission.csv	1.87947	Критическая ошибка/утечка таргета

Список литературы

- [1] Егоров К., *1_data_v6.ipynb*: Инженерия признаков и Walk-Forward валидация, 2026.
- [2] Егоров К., *2_train_blend_v6.ipynb*: Архитектура CatBoost, XGBoost, ZILN MLP и алгоритмы блендинга, 2026.
- [3] Егоров К., *3_extra_tests.ipynb*: Расчет сезонного сдвига (Concept Drift) и постобработка, 2026.
- [4] Google, *Lifetime Value Library*, GitHub Repository, 2020. Доступно по адресу: https://github.com/google/lifetime_value
- [5] Prokhorenkova, L., Gusev, G., Vorobev, A., Dorogush, A. V., & Gulin, A. (2018). *CatBoost: unbiased boosting with categorical features*. Advances in neural information processing systems, 31.
- [6] Chen, T., & Guestrin, C. (2016). *XGBoost: A scalable tree boosting system*. In Proceedings of the 22nd acm sigkdd international conference on knowledge discovery and data mining (pp. 785-794).