

Технический отчёт

Предсказание LTV пользователей

Хакатон по машинному обучению

Задача: Предсказание суммарного GMV пользователей за 30 дней
на основе обезличенных данных активности в Поиске и Каталоге

Участник:	Кирилл Егоров
Метрика:	RMSLE (Root Mean Squared Log Error)
Tie-breaker:	Gini по предсказаниям + RMSPE суммарного GMV
Данные:	250 000 пользователей, 01.01.2025–13.02.2026
Текущий ЛБ:	1.66049 (CatBoost v4a Baseline)
Публичный ЛБ:	20% (50 000 клиентов)
Приватный ЛБ:	80% (200 000 клиентов)
Старт:	10 августа 2026 г.
Дедлайн:	≈ 31 августа 2026 г.
Лимит:	5 сабмитов / день, 2 финальных решения
GPU:	NVIDIA RTX 4050 Laptop (6 ГБ VRAM)

Содержание

1	Описание задачи и данных	1
1.1	Постановка задачи	1
1.2	Особенности исходных данных	1
2	Схема валидации: Walk-Forward Cross-Validation	1
3	История экспериментов: Итерации v1 — v3	1
4	Альтернативные подходы: BTYD и Two-Stage	2
4.1	BTYD (BG/NBD + Gamma-Gamma)	2
4.2	Two-Stage Model	2
5	Итерация v4: Прорыв (Текущий чемпион)	3
5.1	Философия признакового пространства v4	3
5.2	CatBoost v4a Baseline	3
6	Сводная таблица сабмитов (Leaderboard)	4
7	Стратегия финальных ансамблей (5 сабмитов)	4
	Приложение: Ключевые формулы	5

1. Описание задачи и данных

1.1. Постановка задачи

Задача — предсказание **Customer Lifetime Value (LTV)** на горизонте 30 дней. Модель должна по истории активности пользователя предсказать суммарный GMV за период с 14.02.2026 по 15.03.2026.

Публичный / Приватный лидерборд: 20% / 80%!

Оценка на публичном лидерборде вычисляется только по 50 000 из 250 000 клиентов. Это означает высокий риск *public-private shake-up*.

Метрика качества:

$$\text{RMSLE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (\log(1 + \hat{y}_i) - \log(1 + y_i))^2}$$

1.2. Особенности исходных данных

Объём: 30+ млн записей, 250 000 клиентов

Период: 01.01.2025 – 13.02.2026 (407 дней)

Тип: Прореженные временные ряды (спарс).

Особенности целевой переменной: данные сильно **zero-inflated**. Около 45.1% пользователей в обучающей выборке не совершают ни одной покупки ($\text{target} = 0$).

2. Схема валидации: Walk-Forward Cross-Validation

Для временных рядов используется строго **Walk-Forward CV**. Тестировались два подхода к формированию обучающей выборки:

1. **Single-Fold:** обучение только на предыдущем фолде ($\mathcal{D}_{val-1} \rightarrow \mathcal{D}_{val}$). Подход показал наилучшую устойчивость.
2. **Cumulative:** обучение на всех исторических фолдах ($\bigcup_{j=0}^{val-1} \mathcal{D}_j \rightarrow \mathcal{D}_{val}$).

Параметр **stride** (шаг смещения anchor date) критически влияет на качество. При $\text{stride} = 7$ и $\text{target} = 30$ возникало 77%-е перекрытие таргетов между фолдами, что приводило к сильному переобучению алгоритмов (в частности, Optuna). Оптимальным решением признан $\text{stride} = 14$.

3. Эволюция признаков пространства

В процессе разработки пайплайн прошёл через несколько итераций, выявивших ключевые зависимости. Финальным прорывом стала итерация **v4**, где были применены следующие принципы:

1. **Окна полной истории:** добавлены агрегации за 270d и 365d (использование всей истории в 407 дней).
2. **Новые срезы:** `gmw_search`, `gmw_cat`, бинарные флаги `search/cat`.
3. **RFM-метрики:** добавлены `frequency` (`freq_cart`, `active_days`) и `recency` (`recency_cart`, `user_age_days`).

Анализ Feature Importance выявил абсолютное доминирование долгосрочных агрегатов (365d, 270d) и метрик недавности (`recency_ord_days`).

4. Архитектура базовых моделей

4.1. CatBoostRegressor (Чемпион)

Градиентный бустинг с *level-wise* построением деревьев. Обучение производилось по схеме **Single-Fold** на 392 признаках v4. Модель отлично справилась с извлечением сложных нелинейных зависимостей из агрегатов, выдав лучший одиночный результат **1.66049**.

4.2. LightGBM

Градиентный бустинг с *leaf-wise* сплитом. Настроен через Optuna с использованием тех же данных (v4). Благодаря другой архитектуре построения деревьев, модель формирует иное распределение ошибок, что отлично подходит для внутривидовой диверсификации бустингов.

4.3. Рекуррентная нейронная сеть (PyTorch GRU)

В отличие от бустингов, которые оперируют статичными историческими агрегатами (`sum`, `max`, `mean`), **RNN учитывает секвенциальную природу данных**.

Архитектура:

- **Input:** Временные ряды (`SEQ_LEN=120` дней) по 10 признакам (действия в каталоге, поиске, корзине, GMV).
- **Core:** 3-слойный GRU (`hidden_dim=192`, `dropout=0.3`).
- **Head:** Fully Connected слои с LayerNorm и GELU активациями.
- **Обучение:** Optimizer AdamW + CosineAnnealingLR, Loss: MSE на `log1p` таргете.

Роль RNN в пайплайне:

Анализ ансамблей показал, что CatBoost и LightGBM коррелируют между собой на ≈ 0.99 (они практически идентичны). Однако корреляция Пирсона между CatBoost и RNN составляет всего ≈ 0.93 . Именно RNN обеспечивает необходимую **ортогональность ошибок**, что делает её идеальным компонентом для финальных блендов.

5. Альтернативные подходы: BTYD и Two-Stage

Для решения проблемы завышенных нулей (zero-inflation) были протестированы специализированные подходы.

5.1. BTYD (BG/NBD + Gamma-Gamma)

Классическая вероятностная модель поведения покупателей (ноутбук 7_btyd.ipynb). Модель BG/NBD оценивала частоту покупок и вероятность оттока $P(alive)$, а Gamma-Gamma — средний чек. **Результат:** Модель сильно завысила ожидания (средний предсказанный LTV = 85.17, против ≈ 35.35 у CatBoost). Отправка чистого сабмита признана нецелесообразной.

5.2. Two-Stage Model и метод «Zero-Hack»

Двухэтапная архитектура (ноутбук 6_two_stage.ipynb):

- **Stage 1:** CatBoostClassifier предсказывает $P(GMV > 0)$.
- **Stage 2:** CatBoostRegressor обучается *только* на покупателях ($E[GMV|buy]$).

Как самостоятельная модель Two-Stage проиграла бейзлайну. Однако классификатор из **Stage 1** дал важнейший инсайт: оптимальный порог вероятности покупки составляет $P(buy) = 0.46$.

Внедрение «Zero-Hack»:

Предсказания $P(buy)$ из классификатора используются как маска. Зануление предиктов пользователей с $P(buy) < 0.46$ спасает регрессоры от штрафа за предсказание мелких сумм для "спящих" клиентов. Этот метод применяется поверх лучших ML-предсказаний.

6. Сводная таблица сабмитов (Leaderboard)

Ниже представлена полная история отправок решений на платформу, демонстрирующая поэтапное улучшение алгоритмов (отсортировано по улучшению метрики).

7. Стратегия финальных ансамблей (5 сабмитов)

Учитывая доступный лимит в 5 отправок, стратегия построена на использовании чемпиона CatBoost v4a в качестве базы.

Файлы для загрузки на Лидерборд:

1. **Ортогональный бленд v1:** 85% CatBoost v4a + 15% RNN v2.
Нейросеть сгладит редкие выбросы бустинга благодаря своей ортогональности.
2. **Ортогональный бленд v2:** 90% CatBoost v4a + 10% RNN v2.

Таблица 1: История отправок решений на публичный Лидерборд

Имя файла (модель / бленд)	RMSLE	Примечание
catboost_v4a_baseline_submission	1.66049	ЧЕМПИОН (v4)
catboost_baseline_submission	1.67028	Baseline v1
lgbm_v3_submission	1.67115	
catboost_v3_submission	1.67116	
catboost_v4_cumul_submission	1.67126	
catboost_v4_single_submission	1.67177	
blend_cbv3_80_rnnv3_19	1.67380	
blend_cbv3_70_rnnv3_30	1.67583	
ensemble_cb70_rnn30	1.67588	
blend_cbv3_65_rnnv3_35	1.67702	
ensemble_v2_cb70_rnn30	1.68803	
ensemble_v2_cb60_rnn40	1.68942	Утечка v2
catboost_v2_submission	1.69009	Утечка v2
rnn_v2_submission	1.71792	Лучшая RNN
rnn_baseline_submission	1.73624	
btyd_blend_btyd2_cb8	1.76655	
catboost_tuned_submission	1.79400	Провал Optuna v1
btyd_blend_btyd3_cb7	1.81827	Переоценка BTYD

3. **Zero-Hack Champion:** Чистый предикт CatBoost v4a, в котором принудительно установлены нули для пользователей с $P(buy) < 0.46$ (маска от классификатора).
4. **LightGBM v4 (Соло):** Модель LightGBM, обученная на новых мощных признаках v4.
5. **Мощный Бустинг-Бленд:** 60% CatBoost v4a + 40% LightGBM v4.
Диверсификация за счёт комбинации алгоритмов level-wise и leaf-wise сплита.

Приложение: Ключевые формулы

Оценка качества (RMSLE)

$$\text{RMSLE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (\log(1 + \hat{y}_i) - \log(1 + y_i))^2}$$

Log-трансформация

$$\tilde{y} = \log(1 + \max(y, 0)), \quad \hat{y} = \max(e^{\tilde{y}} - 1, 0)$$

Tie-breaker: Gini Normalized

$$G_{norm} = \frac{G(\hat{y}, y)}{G(y, y)} \quad G(a, b) = \frac{1}{n} \left(\frac{\sum_i b_{[a_i \downarrow]} \cdot i}{\sum_i b_i} - \frac{n+1}{2} \right)$$