

Технический отчёт

Предсказание LTV пользователей

Хакатон по машинному обучению

Задача: Предсказание суммарного GMV пользователей за 30 дней
на основе обезличенных данных активности в Поиске и Каталоге

Участник:	Кирилл Егоров
Метрика:	RMSLE (Root Mean Squared Log Error)
Tie-breaker:	Gini по предсказаниям + RMSPE суммарного GMV
Данные:	250 000 пользователей, 01.01.2025–13.02.2026
Финальный ЛБ:	1.65559 (CB 70% + MLP 20% + XGB 10%)
Публичный ЛБ:	20% (50 000 клиентов)
Приватный ЛБ:	80% (200 000 клиентов)
Старт:	10 августа 2026 г.
Дедлайн:	≈ 31 августа 2026 г.
Лимит:	5 сабмитов / день, 2 финальных решения
GPU:	NVIDIA RTX 4050 Laptop (6 ГБ VRAM)

Дата составления: 25 августа 2026 г. (Финальная редакция)

Содержание

1	Описание задачи и данных	1
2	Схема валидации и Признаковое пространство (v6)	1
3	Архитектура Мета-Ансамбля (Stacking)	1
3.1	1. CatBoostRegressor (Базовый фундамент, Вес: 70%)	1
3.2	2. Tabular MLP + ZILN Loss (Вероятностная нейросеть, Вес: 20%) . . .	2
3.3	3. XGBoost (Охотник на нелинейности, Вес: 10%)	2
4	Анализ преодоленных проблем	2
4.1	Взрыв градиентов MLP из-за StandardScaler	2
4.2	Математика предсказаний ZILN	2
4.3	Отказ от Log-Space Blending	2
5	Полная история сабмитов (Leaderboard)	2

1. Описание задачи и данных

Задача — предсказание **Customer Lifetime Value (LTV)** на горизонте 30 дней. Особенности целевой переменной: данные сильно **zero-inflated**. Около 45.1% пользователей в обучающей выборке не совершают ни одной покупки ($\text{target} = 0$).

Публичный / Приватный лидерборд: 20% / 80%!

Оценка на публичном лидерборде вычисляется только по 50 000 из 250 000 клиентов. Это означает высокий риск *public-private shake-up*. Оптимизация моделей строилась на строгой локальной кросс-валидации (OOV) с последующей корректировкой весов блэнда.

2. Схема валидации и Признаковое пространство (v6)

Для временных рядов использовался строго **Walk-Forward CV** ($\text{stride} = 14$ дней). Схема была расширена до **5 фолдов** ($\text{min_history} = 180$ дней) для построения устойчивого мета-ансамбля.

Сгенерировано 435 признаков. Ключевые нововведения версии v6 (Data-Centric AI):

- **Межпокупочные паттерны:** mean/std gap между заказами, метрики регулярности (`order_regularity_cv`).
- **Lifecycle Trajectory:** Ускорение заказов (`order_acceleration`) и GMV slope.
- **Винзоризация таргета (Target Capping):** Ограничение целевой переменной на этапе обучения по 99.9-му перцентилю (4000) для защиты от аномальных "китов".
- **Dormancy & Gaps:** Обработка пустых интервалов числом 999.0 с введением жестких флагов `is_single_buyer` и `is_dormant` (спячка > 120 дней).

3. Архитектура Мета-Ансамбля (Stacking)

Финальное решение построено на максимизации **независимости ошибок** (Error Orthogonality). Итоговый "Трехглавый Франкенштейн" состоит из трех SOTA-моделей:

3.1. 1. CatBoostRegressor (Базовый фундамент, Вес: 70%)

Градиентный бустинг с *level-wise* (oblivious) построением деревьев на 435 признаках. Применена техника **Seed Averaging**: усреднение предсказаний 5 моделей с разными seed-значениями для радикального снижения дисперсии.

3.2. 2. Tabular MLP + ZILN Loss (Вероятностная нейросеть, Вес: 20%)

Полносвязный 4-слойный перцептрон, обученный на сглаженных признаках. Использует функцию потерь ZILN (*Zero-Inflated Lognormal Loss*), которая одновременно решает задачи классификации (купит ли?) и регрессии (сколько потратит?). Модель отлично генерализует нелинейности. После перехода на данные v6 показала рекордную сходимость.

3.3. 3. XGBoost (Охотник на нелинейности, Вес: 10%)

Асимметричный градиентный бустинг с глубокой L1-регуляризацией (`reg_alpha = 2.0`). За счет асимметрии нашел паттерны, недоступные CatBoost, что позволило увеличить его вес в финальном бленде до 10%.

4. Анализ преодолённых проблем

4.1. Взрыв градиентов MLP из-за StandardScaler

Применение классического `StandardScaler` привело к катастрофическому росту Loss ($\text{RMSLE} \approx 1.89$). Проблема была решена переходом на `QuantileTransformer` (`output_distribution="normal"`), который аккуратно уложил все выбросы в идеальный колокол гауссианы.

4.2. Математика предсказаний ZILN

Извлечение медианы из ZILN Loss ($p \cdot \exp(\mu)$) давало сильную недооценку LTV. Переключение на формулу минимизации логарифмической ошибки ($\exp(p \cdot \mu) - 1$) восстановило метрику RMSLE до чемпионских значений.

4.3. Отказ от автоматического Ridge Stacking

Модель XGBoost показала сильный локальный OOF, что заставило Ridge-оптимизатор выделить ей до 70% веса. Из-за "OOF-LB Shake-up" это привело бы к падению метрики на реальном тесте. Был применен **Умный ручной стэкинг**.

5. Отклоненные гипотезы и стратегии

В процессе разработки и эволюции пайплайна был протестирован и отвергнут ряд подходов (см. таблицу сабмитов):

- **Вероятностные модели BTYD (Buy Till You Die):** Классические модели (BG/NBD, Gamma-Gamma) показали крайне слабую способность предсказывать LTV на коротком горизонте (30 дней) для zero-inflated данных ($\text{RMSLE} > 1.76$).

- **Рекуррентные нейросети (RNN/LSTM):** Несмотря на временную природу данных, RNN сильно уступали градиентному бустингу и полносвязным сетям (MLP) при работе с разреженными агрегированными признаками.
- **LightGBM:** Специфика построения деревьев (leaf-wise) приводила к мгновенному переобучению на "китах" (аномальных выбросах таргета), из-за чего модель оказалась крайне нестабильной.
- **Логарифмический блендинг (Log-Space Stacking):** Усреднение логарифмов предсказаний (геометрическое среднее) слишком сильно занижало прогнозы для крупных покупателей, что жестоко штрафовалось метрикой RMSLE. Арифметическое усреднение оказалось математически корректнее.
- **Переобучение через Optuna:** Глубокий поиск гиперпараметров (`depth=8`) показал феноменальный результат на локальной валидации (1.634), но привел к сильному падению на тесте (1.662). Был выполнен откат к жестко регуляризованному CatBoost (`depth=6`).
- **Псевдо-разметка (Pseudo-Labeling):** Метод был отклонен для минимизации риска public-private shake-up на скрытой части лидерборда (80% данных).

6. Полная история сабмитов (Leaderboard)

В таблицах ниже задокументированы все 54 итерации отправок, отсортированные по улучшению метрики (от лучших к худшим).

Таблица 1: Полная история результатов (Часть 1: Топ-27)

Имя файла (модель / бленд)	RMSLE	Примечание
v6_arithmetic_cb70_mlp20_xgb10	1.65559	ФИНАЛЬНЫЙ ЧЕМПИОН (Мета-ансамбль v6)
v6_arithmetic_cb75_mlp15_xgb10	1.65574	Осторожный бленд v6
arithmetic_cb75_mlp15_xgb10.csv	1.65581	Промежуточный бленд v5
arithmetic_cb75_mlp20_xgb05.csv	1.65584	
FINAL_blend_cb80_mlp15_xgb05	1.65590	
arithmetic_cb85_mlp10_xgb05.csv	1.65601	
FINAL_blend_cb85_mlp15.csv	1.65605	Двуглавый бленд v5
catboost_v5_seed_avg.csv	1.65656	
catboost_v6_seed_avg.csv	1.65678	Соло CatBoost на данных v6
blend_seed_avg_92_rnn8.csv	1.65878	Бывший чемпион (v4b + RNN v2)
blend_seed_avg_90_rnn10.csv	1.65884	
blend_seed_avg_95_rnn5.csv	1.65890	
frank_cb70_ziln20_xgb5_rnn5	1.65912	Промежуточный бленд (v4)
frank_cb75_ziln20_rnn5.csv	1.65912	
blend_pseudo_90_rnn10.csv	1.65929	Эксперимент с псевдо-разметкой
blend_ortho_90_10.csv	1.65935	
logblend_cb800_mlp150_xgb50.csv	1.65975	Отказ от Log-Space блендинга
frank_cb70_ziln15_rnn15.csv	1.65977	
catboost_v4a_seed_avg.csv	1.65984	Базовый CatBoost v4 (Seed Avg)
blend_ortho_85_15.csv	1.65992	
ziln_v6_v1_submission.csv	1.66008	Рекорд соло-нейросети (данные v6)
catboost_v4a_baseline.csv	1.66049	
blend_v4a_ortho_95_05.csv	1.66071	
blend_v4a_ortho_90_10.csv	1.66113	
ziln_v5_v1_submission.csv	1.66220	
catboost_v5_seed_avg.csv	1.66265	Оверфит на валидации через Optuna
blend_v4a60_lgbm40.csv	1.66336	

Таблица 2: Полная история результатов (Часть 2: Остальные отправки)

Имя файла (модель / бленд)	RMSLE	Примечание
xgboost_v6_submission.csv	1.66478	
xgboost_v5_submission.csv	1.66506	XGBoost с логарифмированным таргетом
mlp_ziln_submission.csv	1.66545	MLP ZILN на v4 фичах
catboost_baseline_sub.csv	1.67028	Baseline v1 (от организаторов)
xgboost_log_submission.csv	1.67102	XGBoost v4
lgbm_v3_submission.csv	1.67115	
catboost_v3_submission.csv	1.67116	
catboost_v4_cumul_sub.csv	1.67126	
catboost_v4_single_sub.csv	1.67177	
blend_cbv3_80_rnnv3_19.csv	1.67380	
blend_cbv3_70_rnnv3_30.csv	1.67583	
ensemble_cb70_rnn30.csv	1.67588	
blend_cbv3_65_rnnv3_35.csv	1.67702	
lgbm_v4_submission.csv	1.68433	Нестабильность LGBM
ensemble_v2_cb70_rnn30.csv	1.68803	Утечка v2
ensemble_v2_cb60_rnn40.csv	1.68942	Утечка v2
catboost_v2_submission.csv	1.69009	Утечка v2
lgbm_v4_submission.csv	1.70118	
rnn_v4_submission.csv	1.70489	Соло RNN v4
rnn_v2_submission.csv	1.71792	Соло RNN v2
catboost_v4a_zero_hacked.csv	1.73573	Провал гипотезы жестких нулей
rnn_baseline_sub.csv	1.73624	
xgboost_sqrt_submission.csv	1.75422	Провал трансформации Sqrt
btzd_blend_btyd2_cb8.csv	1.76655	Провал вероятностной модели (BTYD)
catboost_tuned_submission.csv	1.79400	Провал Optuna v1
btzd_blend_btyd3_cb7.csv	1.81827	
rnn_v4_submission.csv	1.87947	Утечка таргета