

Технический отчёт

Предсказание LTV пользователей

Хакатон по машинному обучению

Задача: Предсказание суммарного GMV пользователей за 30 дней
на основе обезличенных данных активности в Поиске и Каталоге

Участник:	Кирилл Егоров
Метрика:	RMSLE (Root Mean Squared Log Error)
Tie-breaker:	Gini по предсказаниям + RMSPE суммарного GMV
Данные:	250 000 пользователей, 01.01.2025–13.02.2026
Текущий ЛБ:	1.65935 (Blend Ortho 90/10)
Публичный ЛБ:	20% (50 000 клиентов)
Приватный ЛБ:	80% (200 000 клиентов)
Старт:	10 августа 2026 г.
Дедлайн:	≈ 31 августа 2026 г.
Лимит:	5 сабмитов / день, 2 финальных решения
GPU:	NVIDIA RTX 4050 Laptop (6 ГБ VRAM)

Дата составления: 18 августа 2026 г. (Обновление после 5-й итерации)

Содержание

1	Описание задачи и данных	1
1.1	Постановка задачи	1
1.2	Особенности исходных данных	1
2	Схема валидации: Walk-Forward Cross-Validation	1
3	Эволюция признакового пространства	1
4	Архитектура базовых моделей	2
4.1	CatBoostRegressor (Основа решения)	2
4.2	LightGBM	2
4.3	Рекуррентная нейронная сеть (PyTorch GRU)	3
5	Вычислительная сложность и время выполнения	3
6	Анализ неудачных подходов (BTYD и Zero-Hack)	3
6.1	BTYD (BG/NBD + Gamma-Gamma)	3
6.2	Провал метода «Zero-Hack»	3
7	Сводная таблица сабмитов (Leaderboard)	4
8	Стратегия на финальные отправки	4
	Приложение: Ключевые формулы	5

1. Описание задачи и данных

1.1. Постановка задачи

Задача — предсказание **Customer Lifetime Value (LTV)** на горизонте 30 дней. Модель должна по истории активности пользователя предсказать суммарный GMV за период с 14.02.2026 по 15.03.2026.

Публичный / Приватный лидерборд: 20% / 80%!

Оценка на публичном лидерборде вычисляется только по 50 000 из 250 000 клиентов. Это означает высокий риск *public-private shake-up*.

Метрика качества:

$$\text{RMSLE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (\log(1 + \hat{y}_i) - \log(1 + y_i))^2}$$

1.2. Особенности исходных данных

Объём: 30+ млн записей, 250 000 клиентов

Период: 01.01.2025 – 13.02.2026 (407 дней)

Тип: Прореженные временные ряды (спарс).

Особенности целевой переменной: данные сильно **zero-inflated**. Около 45.1% пользователей в обучающей выборке не совершают ни одной покупки ($\text{target} = 0$).

2. Схема валидации: Walk-Forward Cross-Validation

Для временных рядов используется строго **Walk-Forward CV**. Тестировались два подхода к формированию обучающей выборки:

1. **Single-Fold:** обучение только на предыдущем фолде ($\mathcal{D}_{val-1} \rightarrow \mathcal{D}_{val}$). Подход показал наилучшую устойчивость.
2. **Cumulative:** обучение на всех исторических фолдах ($\bigcup_{j=0}^{val-1} \mathcal{D}_j \rightarrow \mathcal{D}_{val}$).

Параметр **stride** (шаг смещения anchor date) критически влияет на качество. При $\text{stride} = 7$ и $\text{target} = 30$ возникало 77%-е перекрытие таргетов между фолдами, что приводило к сильному переобучению алгоритмов (в частности, Optuna). Оптимальным решением признан $\text{stride} = 14$.

3. Эволюция признаковового пространства

В процессе разработки пайплайн прошёл через несколько итераций, выявивших ключевые зависимости. Финальным прорывом стала итерация **v4**, где были применены следующие принципы:

1. **Окна полной истории:** добавлены агрегации за 270d и 365d (использование всей истории в 407 дней).
2. **Новые срезы:** `gmw_search`, `gmw_cat`, бинарные флаги `search/cat`.
3. **RFM-метрики:** добавлены frequency (`freq_cart`, `active_days`) и recency (`recency_cart`, `user_age_days`).

Анализ Feature Importance выявил абсолютное доминирование долгосрочных агрегатов (365d, 270d) и метрик недавности (`recency_ord_days`).

Таблица 1: Признаки исходных данных

Колонка	Тип	Описание
<code>event_date</code>	date	Дата активности
<code>user_id</code>	int	Идентификатор пользователя
<code>search</code>	flag	Использование Поиска
<code>cat</code>	flag	Использование Каталога
<code>has_search_to_cart</code>	flag	Товар в корзину (Поиск)
<code>has_search_to_ord</code>	flag	Покупка (Поиск)
<code>has_cat_to_cart</code>	flag	Товар в корзину (Каталог)
<code>has_cat_to_ord</code>	flag	Покупка (Каталог)
<code>searches</code>	int	Поисковые запросы
<code>search_to_cart</code>	int	В корзину (Поиск)
<code>search_to_ord</code>	int	Куплено (Поиск)
<code>cat_to_cart</code>	int	В корзину (Каталог)
<code>cat_to_ord</code>	int	Куплено (Каталог)
<code>to_cart</code>	int	Всего в корзину
<code>to_ord</code>	int	Всего куплено
<code>gmw_search</code>	float	GMV из Поиска
<code>gmw_cat</code>	float	GMV из Каталога
<code>gmw</code>	float	Суммарный GMV (таргет)

4. Архитектура базовых моделей

4.1. CatBoostRegressor (Основа решения)

Градиентный бустинг с *level-wise* построением деревьев. Обучение производилось по схеме **Single-Fold** на 392 признаках v4. Выдал лучший одиночный результат **1.66049**.

4.2. LightGBM

Градиентный бустинг с *leaf-wise* сплитом. Настроен через Optuna. Благодаря другой архитектуре построения деревьев, модель формирует иное распределение ошибок, что отлично подходит для диверсификации.

4.3. Рекуррентная нейронная сеть (PyTorch GRU)

RNN учитывает секвенциальную природу данных, оперируя окнами в 180 дней. Архитектура: 3-слойный GRU (hidden_dim=192), Optimizer AdamW + CosineAnnealingLR.

Роль RNN в пайплайне:

Именно RNN обеспечила необходимую **ортогональность ошибок**. Смешивание 90% предсказаний CatBoost и 10% предсказаний RNN дало синергетический эффект, установив абсолютный рекорд на лидерборде.

5. Вычислительная сложность и время выполнения

Пайплайн оптимизирован для выполнения на локальной машине с GPU (NVIDIA RTX 4050 Laptop, 6 ГБ VRAM).

Таблица 2: Примерное время выполнения основных этапов пайплайна

Этап / Модель	Время	Комментарий
Генерация признаков (v4)	≈ 30–40 мин	30+ млн строк в Polars, 392 фичи.
Optuna тюнинг (CB/LGBM)	≈ 40–60 мин	Выполнение на GPU (20 триалов).
Обучение CatBoost (v4a)	≈ 10–15 мин	Быстрое обучение на 1 фолде.
Обучение LightGBM (v4)	≈ 10–15 мин	Обучение алгоритма leaf-wise на GPU.
Обучение RNN (GRU)	≈ 353 мин	Самый сложный этап (≈ 6 ч). 3-слойная сеть.
Ансамблирование и сабмиты	< 1 мин	Линейный блендинг.

6. Анализ неудачных подходов (BTYD и Zero-Hack)

6.1. BTYD (BG/NBD + Gamma-Gamma)

Вероятностная модель сильно зависила ожидания (средний предсказанный LTV = 85.17, против ≈ 35 у CatBoost). Отправка чистого сабмита дала скор > 1.81.

6.2. Провал метода «Zero-Hack»

В модели Two-Stage классификатор предсказывал вероятность покупки $P(buy)$. Была выдвинута гипотеза занулять финальный GMV для пользователей с $P(buy) < 0.46$. На публичном лидерборде этот метод показал **катастрофическое падение скор (1.73573)**. **Вывод:** Метрика RMSLE крайне жестко штрафует за предсказание абсолютного нуля, если клиент всё же совершил покупку. Искусственное зануление признано опасным и исключено из пайплайна.

7. Сводная таблица сабмитов (Leaderboard)

Ниже представлена актуальная история отправок решений, отсортированная по метрике RMSLE.

Таблица 3: Актуальные результаты на публичном Лидерборде

Имя файла (модель / бленд)	RMSLE	Примечание
blend_ortho_90_10.csv	1.65935	ЧЕМПИОН (СВ 90% + RNN 10%)
blend_ortho_85_15.csv	1.65992	Отличная синергия
catboost_v4a_baseline_submission	1.66049	Лучший одиночный предикт
blend_v4a60_lgbm40.csv	1.66336	LGBM на старых фичах
catboost_baseline_submission	1.67028	Baseline v1
lgbm_v3_submission	1.67115	
catboost_v3_submission	1.67116	
catboost_v4_cumul_submission	1.67126	
catboost_v4_single_submission	1.67177	
blend_cbv3_80_rnnv3_19	1.67380	
blend_cbv3_70_rnnv3_30	1.67583	
ensemble_cb70_rnn30	1.67588	
blend_cbv3_65_rnnv3_35	1.67702	
lgbm_v4_submission	1.68433	Ошибка загрузки feature_importance
ensemble_v2_cb70_rnn30	1.68803	
ensemble_v2_cb60_rnn40	1.68942	Утечка v2
catboost_v2_submission	1.69009	Утечка v2
rnn_v2_submission	1.71792	База для ансамбля орто
catboost_v4a_zero_hacked	1.73573	Провал гипотезы нулей
rnn_baseline_submission	1.73624	
btyd_blend_btyd2_cb8	1.76655	
catboost_tuned_submission	1.79400	Провал Optuna v1
btyd_blend_btyd3_cb7	1.81827	Переоценка BTYD

8. Стратегия на финальные отправки

Текущий рекорд 1.65935 достигнут за счёт ансамблирования. Дальнейшие шаги фокусируются на эксплуатации этой синергии:

- Тонкий тюнинг весов (Micro-blending):** Так как пропорция 90/10 превзошла 85/15, необходимо исследовать крайние значения (например, 95/5 или 93/7), чтобы найти абсолютный оптимум.
- Перезапуск LightGBM:** Обучение LightGBM на корректном топе признаков v4.

3. **Разработка RNN v4:** Обучение нейросети на обновленных данных (использование `SEQ_LEN = 180` и включение флагов каталога/поиска), чтобы повысить качество базового предикта перед блендингом.
4. **Pseudo-labeling (Псевдо-разметка):** Использование наиболее уверенных предсказаний из текущего лучшего сабмита в качестве истинных меток для расширения обучающей выборки CatBoost. Этот метод позволяет модели выучить скрытую структуру тестовой выборки.

Приложение: Ключевые формулы

Оценка качества (RMSLE)

$$\text{RMSLE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (\log(1 + \hat{y}_i) - \log(1 + y_i))^2}$$

Log-трансформация

$$\tilde{y} = \log(1 + \max(y, 0)), \quad \hat{y} = \max(e^{\tilde{y}} - 1, 0)$$