

Технический отчёт

Предсказание LTV пользователей

Хакатон по машинному обучению

Задача: Предсказание суммарного GMV пользователей за 30 дней
на основе обезличенных данных активности в Поиске и Каталоге

Участник:	Кирилл Егоров
Метрика:	RMSLE (Root Mean Squared Log Error)
Данные:	250 000 пользователей, 01.01.2025–13.02.2026
Финальный ЛБ:	1.65305 (CB 70% + MLP 20% + XGB 10% $\times$ 1.12375)
GPU:	NVIDIA RTX 4050 Laptop (6 ГБ VRAM)

Дата составления: 29 августа 2026 г.

Содержание

1	Теоретический базис и математическая модель	1
1.1	Нейросетевая модель: Tabular MLP и ZILN	1
1.2	Градиентный бустинг: CatBoost и XGBoost	1
2	Архитектура решения и инженерия признаков	2
2.1	Схема валидации и алгоритмы стабилизации	2
2.2	Конвейер генерации признаков (Feature Engineering)	2
3	Успешные исследования и тестирование гипотез	2
4	Анализ отвергнутых гипотез	3
5	Валидация пайплайна и результаты	4

1. Теоретический базис и математическая модель

Оценка качества предсказаний Customer Lifetime Value (LTV) производится с помощью логарифмической метрики Root Mean Squared Logarithmic Error (RMSLE). Фундаментальная сложность заключается в смешанном (Zero-Inflated) распределении целевой переменной: порядка 46.4% пользователей в выборке не совершают ни одной транзакции в прогнозном окне (`target = 0`) [2].

1.1. Нейросетевая модель: Tabular MLP и ZILN

Для корректного моделирования нулевых и положительных трат была разработана вероятностная архитектура с применением функции потерь **Zero-Inflated LogNormal (ZILN)**. Сеть аппроксимирует три логита $\mathbf{z} = (z_0, z_1, z_2)$, которые трансформируются в параметры распределения [2]:

$$p = \frac{1}{1 + \exp(-z_0)}, \quad \mu = z_1, \quad \sigma = \log(1 + \exp(z_2))$$

Итоговая функция потерь объединяет бинарную кросс-энтропию (BCE) и негативное логарифмическое правдоподобие (NLL) [5, 2]:

$$\mathcal{L} = -\mathbb{I}_{y=0} \log(1 - p) - \mathbb{I}_{y>0} \left[\log(p) - \frac{\log(\sigma\sqrt{2\pi}) + (\log y - \mu)^2}{2\sigma^2} \right]$$

Для извлечения финального предсказания применена эмпирически выведенная формула, напрямую минимизирующая логарифмический штраф метрики хакатона [2]:

$$\hat{y} = \exp(p \cdot \mu) - 1$$

1.2. Градиентный бустинг: CatBoost и XGBoost

Обе древовидные модели оптимизировались под метрику RMSE на предварительно логарифмированном таргете $\tilde{y}_i = \log(1 + y_i)$ [2].

CatBoost использует симметричные (oblivious) деревья решений, где один и тот же предикат расщепления применяется ко всему уровню дерева [6]. Итоговый прогноз формируется суммированием весов листьев:

$$F(x) = \sum_{k=1}^K c_k \mathbb{I}(x \in R_k)$$

XGBoost строит несимметричные деревья, применяя алгоритм гистограммного поиска сплитов. Применяется строгая оптимизация с L_1 (α) и L_2 (λ) регуляризацией листьев w_k [7, 2]:

$$\mathcal{L}_{\text{XGB}} = \sum_{i=1}^N \frac{1}{2} (\tilde{y}_i - \hat{y}_i)^2 + \sum_{k=1}^K \left(\gamma T_k + \frac{1}{2} \lambda \|w_k\|^2 + \alpha \|w_k\|_1 \right)$$

В пайплайне заданы веса $\alpha = 2.0, \lambda = 5.0$, что жестко штрафует сложные деревья и выявляет скрытые нелинейные паттерны [2].

2. Архитектура решения и инженерия признаков

2.1. Схема валидации и алгоритмы стабилизации

Для исключения эффекта «заглядывания в будущее» реализован алгоритм **Walk-Forward Cross-Validation** [1]. Анкорная дата t_{anchor} последовательно сдвигается на шаг S (14 дней), формируя независимые обучающие и валидационные блоки:

$$\text{Train}_k = \{(x_i, y_i) \mid t_i \in [t_{\text{anchor}}^{(k)} - H, t_{\text{anchor}}^{(k)}]\}$$

$$\text{Val}_k = \{(x_i, y_i) \mid t_i \in [t_{\text{anchor}}^{(k)} + 1, t_{\text{anchor}}^{(k)} + 30]\}$$

где H — глубина исторического окна (180 дней) [1].

Для снижения дисперсии градиентного бустинга применена техника **Seed Averaging**. Итоговый прогноз базовой модели CatBoost $\hat{y}_{\text{CB}}$ формируется как арифметическое среднее предсказаний 5 моделей, обученных с различными седами [2]:

$$\hat{y}_{\text{CB}}(x) = \frac{1}{5} \sum_{m=1}^5 F_m(x; \text{seed}_m)$$

2.2. Конвейер генерации признаков (Feature Engineering)

На базе библиотеки **Polars** реализована генерация 437 признаков [1].

- **Lifecycle Trajectory:** Отношение трат за последовательные периоды позволило вычислить метрики ускорения заказов (`order_acceleration`):

$$\text{Accel} = \frac{\text{Ord}_{w1} + \epsilon}{\text{Ord}_{w2} + \epsilon} - \frac{\text{Ord}_{w3} + \epsilon}{\text{Ord}_{w4} + \epsilon}$$

- **Межпокупочные интервалы (Gaps):** Расчет математического ожидания (`mean_order_gap`) и стандартного отклонения (`std_order_gap`). Коэффициент вариации σ/μ (`order_regularity_cv`) позволил оценивать стабильность спроса. Пустые интервалы заполнялись значением 999.0 [1].
- **Индикация оттока:** Созданы бинарные флаги `is_single_buyer` и `is_dormant`. Последний активируется для пользователей без покупок более 120 дней [1].
- **Винзоризация таргета (Target Capping):** Целевая переменная жестко ограничивалась по 99.9-му перцентилю (4000.0) для защиты градиентов от аномальных «китов» [1].

3. Успешные исследования и тестирование гипотез

1. Опровержение гипотезы отдельных моделей (Two-Stage Pipeline). Обучение отдельного бинарного классификатора и регрессора приводило к перемножению ошибок моделей. Внедрение единой нейросети (Tabular MLP) с функцией ZILN

Loss математически корректно связало вероятности p и μ на уровне градиентов, что дало значительный прирост OOF-метрики [2].

2. Трансформация признакового пространства. Использование `StandardScaler` приводило к коллапсу нейросети из-за выбросов. Переход на `QuantileTransformer` жестко нормализовал все признаки в идеальную гауссиану в границах $[-5.0, 5.0]$, обеспечив стабильную сходимость [2].

3. Выявление сезонного сдвига (Seasonal Concept Drift). Анализ исторических логов показал, что тестовая выборка (14.02 - 15.03) подвержена весенней сезонности. По данным 2025 года конверсия в этот месяц росла с 37.23% до 40.29%, а средний чек с 59.53 до 59.97 [3]. Был рассчитан теоретический мультипликатор 1.0901, который в ходе бинарного поиска был уточнен до эмпирического оптимума 1.12375 [3].

4. Анализ отвергнутых гипотез

Опираясь на историю отправок (раздел 5), ряд подходов был классифицирован как математически или алгоритмически неэффективный для текущей задачи [4]:

- **Пороговое масштабирование (Smart Multiplier):** Гипотеза о том, что праздничный рост затронул только лояльных клиентов (пороги 100, 300, 500 рублей), не подтвердилась. Ограничение буста только для "китов" ухудшило скор до 1.65535–1.65575. Это доказало, что весенний сдвиг равномерно затронул всю аудиторию, включая микро-покупки.
- **Микро-сдвиг базовой вероятности (Offset):** Искусственное добавление константы $+0.1$ ко всем предсказаниям уронило метрику до 1.65413. Это подтвердило фундаментальное правило RMSLE: искажение строгих нулей массово штрафует и нивелирует любую пользу от вытягивания скрытых покупателей.
- **Пост-клиппинг выбросов:** Ограничение финальных прогнозов максимумом в 4000.0 (`v6_champ_clipped_4000.csv`) показало результат, идентичный основному сабмиту (1.653058). Это подтвердило, что ансамбль математически стабилен и изначально не генерировал аномальных выбросов даже после умножения.
- **Вероятностные BTYD-модели (Buy Till You Die):** Классические алгоритмы (BG/NBD) показали неспособность прогнозировать LTV на коротком 30-дневном горизонте ($\text{RMSLE} > 1.76$) [4].
- **Логарифмический блендинг (Log-Space Blending):** Геометрическое усреднение предсказаний слишком сильно пессимизировало прогнозы для крупных покупателей, уступив линейному арифметическому бленду ($\text{RMSLE} 1.65975$) [4].
- **Автоматический тюнинг (Optuna):** Поиск гиперпараметров вызвал переобучение на валидационной выборке ($\text{RMSLE} 1.79400$). Ручной подбор с глубокой регуляризацией оказался стабильнее [4].

5. Валидация пайплайна и результаты

Для финального решения использовался арифметический блендинг предсказаний с весами, оптимизированными для достижения максимальной ортогональности ошибок [2]:

- **CatBoost (70%)**: Стабильный базовый прогноз (OOF RMSLE: 1.66115).
- **Tabular MLP ZILN (20%)**: Сглаживает нулевых покупателей (OOF RMSLE: 1.66912).
- **XGBoost (10%)**: Корректировщик нелинейностей (OOF RMSLE: 1.64183).

Итоговый бленд без масштабирования показал OOF RMSLE 1.65559, а применение сезонного множителя 1.12375 вывело решение на финальный скор **1.65305** [3, 4]. Ниже представлена полная эволюция качества пайплайна.

Таблица 1: Часть 1: Чемпионы, тюнинги и проверка гипотез

Имя файла	RMSLE	Примечание
v6_champion_mult_1.12375.csv	1.65305	Абсолютный оптимум (Множитель 1.12375)
v6_champ_clipped_4000.csv	1.65306	Идентичный результат (отсутствие выбросов >4000)
v6_champion_mult_1.125.csv	1.65305	Бинарный поиск множителя
v6_champion_mult_1.1225.csv	1.65305	Бинарный поиск множителя
v6_champion_mult_1.12.csv	1.65306	Разведка правой границы
v6_champion_mult_1.13.csv	1.65306	Разведка правой границы
v6_champion_mult_1.14.csv	1.65309	Подтверждение экстремума
v6_champion_mult_1.10.csv	1.65313	Приближение к дну
v6_champion_mult_1.09.csv	1.65321	Расчетный сдвиг 2025 года
v6_champion_mult_1.05.csv	1.65389	Успешный старт калибровки
v6_champ_offset_0.1.csv	1.65413	Микро-сдвиг базового прогноза (+0.1)
v6_champion_mult_1.03.csv	1.65445	
v6_champion_mult_1.02.csv	1.65479	
v6_smart_mult_th_100.csv	1.65535	Пороговое умножение (от 100)
v6_arithmetic_cb70_mlp20_xgb10	1.65559	Лучший чистый базовый ансамбль
v6_arithmetic_cb65_mlp25_xgb10	1.65566	Тест увеличенной доли MLP
v6_arithmetic_cb65_mlp20_xgb15	1.65568	Тест увеличенной доли XGBoost
v6_smart_mult_th_500.csv	1.65573	Пороговое умножение (от 500)
v6_arithmetic_cb75_mlp15_xgb10	1.65574	
v6_smart_mult_th_300.csv	1.65575	Пороговое умножение (от 300)
arithmetic_cb75_mlp15_xgb10.csv	1.65581	
arithmetic_cb75_mlp20_xgb05.csv	1.65584	
FINAL_blend_cb80_mlp15_xgb05	1.65590	
arithmetic_cb85_mlp10_xgb05.csv	1.65601	
FINAL_blend_cb85_mlp15.csv	1.65605	
v6_champion_mult_0.98.csv	1.65655	Ухудшение (занижение прогноза)
catboost_v5_seed_avg.csv	1.65656	
catboost_v6_seed_avg.csv	1.65678	Соло CatBoost (v6)
v6_champion_mult_0.97.csv	1.65710	

Таблица 2: Часть 2: Поиск базового ансамбля и эксперименты (25–46)

Имя файла	RMSLE	Примечание
blend_seed_avg_92_rnn8.csv	1.65878	Бывший лидер (v4b + RNN)
blend_seed_avg_90_rnn10.csv	1.65884	
blend_seed_avg_95_rnn5.csv	1.65890	
frank_cb70_ziln20_xgb5_rnn5.csv	1.65912	
frank_cb75_ziln20_rnn5.csv	1.65912	
blend_pseudo_90_rnn10.csv	1.65929	Эксперимент с pseudo-labeling
blend_ortho_90_10.csv	1.65935	
logblend_cb800_mlp150_xgb50.csv	1.65975	Отказ от Log-Space блендинга
frank_cb70_ziln15_rnn15.csv	1.65977	
catboost_v4a_seed_avg.csv	1.65984	Рекорд соло-нейросети ZILN (v6)
blend_ortho_85_15.csv	1.65992	
ziln_v6_v1_submission.csv	1.66008	
catboost_v4a_baseline_sub...	1.66049	
blend_v4a_ortho_95_05.csv	1.66071	
blend_v4a_ortho_90_10.csv	1.66113	Оверфит Optuna
ziln_v5_v1_submission.csv	1.66220	
catboost_v5_seed_avg.csv	1.66265	
blend_v4a60_lgbm40.csv	1.66336	
xgboost_v6_submission.csv	1.66478	
xgboost_v5_submission.csv	1.66506	Соло XGBoost (v6)
mlp_ziln_submission.csv	1.66545	
catboost_baseline_submission	1.67028	Baseline от организаторов

Таблица 3: Часть 3: Ранние версии, утечки и бейзлайны (47–68)

Имя файла	RMSLE	Примечание
xgboost_log_submission.csv	1.67102	
lgbm_v3_submission.csv	1.67115	
catboost_v3_submission.csv	1.67116	
catboost_v4_cumul_sub...	1.67126	
catboost_v4_single_sub...	1.67177	
blend_cbv3_80_rnnv3_19.csv	1.67380	
blend_cbv3_70_rnnv3_30.csv	1.67583	
ensemble_cb70_rnn30.csv	1.67588	
blend_cbv3_65_rnnv3_35.csv	1.67702	
lgbm_v4_submission.csv	1.68433	Нестабильность LightGBM
ensemble_v2_cb70_rnn30.csv	1.68803	Утечка данных в v2
ensemble_v2_cb60_rnn40.csv	1.68942	Утечка данных в v2
catboost_v2_submission.csv	1.69009	Утечка данных в v2
lgbm_v4_submission.csv	1.70118	
rnn_v4_submission.csv	1.70489	Соло RNN (v4)
rnn_v2_submission.csv	1.71792	
catboost_v4a_zero_hacked	1.73573	Провал гипотезы жестких нулей
rnn_baseline_submission.csv	1.73624	
btzd_blend_btyd2_cb8.csv	1.76655	Провал вероятностной модели BTYD
catboost_tuned_submission	1.79400	Провал поиска параметров Optuna v1
btzd_blend_btyd3_cb7.csv	1.81827	
rnn_v4_submission.csv	1.87947	Критическая ошибка/утечка таргета

Список литературы

- [1] Егоров К., *1_data_v6.ipynb*: Инженерия признаков и Walk-Forward валидация, 2026.
- [2] Егоров К., *2_train_blend_v6.ipynb*: Архитектура CatBoost, XGBoost, ZILN MLP и алгоритмы блендинга, 2026.
- [3] Егоров К., *3_extra_tests.ipynb*: Расчет сезонного сдвига (Concept Drift) и постобработка, 2026.
- [4] Егоров К., *Отчёт по хакатону: LTV-предсказание (report_2.pdf)*, 2026.
- [5] Google, *Lifetime Value Library*, GitHub Repository, 2020. Доступно по адресу: https://github.com/google/lifetime_value
- [6] Prokhorenkova, L., Gusev, G., Vorobev, A., Dorogush, A. V., & Gulin, A. (2018). *CatBoost: unbiased boosting with categorical features*. Advances in neural information processing systems, 31.
- [7] Chen, T., & Guestrin, C. (2016). *XGBoost: A scalable tree boosting system*. In Proceedings of the 22nd acm sigkdd international conference on knowledge discovery and data mining (pp. 785-794).