

Технический отчёт

Предсказание LTV пользователей

Хакатон по машинному обучению

Задача: Предсказание суммарного GMV пользователей за 30 дней
на основе обезличенных данных активности в Поиске и Каталоге

Участник:	Кирилл Егоров
Метрика:	RMSLE (Root Mean Squared Log Error)
Tie-breaker:	Gini по предсказаниям + RMSPE суммарного GMV
Данные:	250 000 пользователей, 01.01.2025–13.02.2026
Финальный ЛБ:	1.65305 (CB 70% + MLP 20% + XGB 10% $\times 1.12375$)
Публичный ЛБ:	20% (50 000 клиентов)
Приватный ЛБ:	80% (200 000 клиентов)
Старт:	10 августа 2026 г.
Дедлайн:	$\approx$ 31 августа 2026 г.
Лимит:	5 сабмитов / день, 2 финальных решения
GPU:	NVIDIA RTX 4050 Laptop (6 ГБ VRAM)

Содержание

1	Описание задачи и данных	1
2	Эволюция признакового пространства и схема валидации	1
2.1	Исторические версии данных (v1 – v5)	1
2.2	Финальная версия v6 (Data-Centric AI)	1
3	Архитектура Мета-Ансамбля (Stacking)	2
3.1	1. CatBoostRegressor (Базовый фундамент, Вес: 70%)	2
3.2	2. Tabular MLP + ZILN Loss (Вероятностная нейросеть, Вес: 20%)	2
3.3	3. XGBoost (Охотник на нелинейности, Вес: 10%)	2
4	Анализ преодоленных проблем	2
4.1	Взрыв градиентов MLP из-за StandardScaler	2
4.2	Сезонный сдвиг (Concept Drift) и Праздничные множители	2
5	Отклоненные гипотезы и стратегии	3
6	Полная история сабмитов (Leaderboard)	3

1. Описание задачи и данных

Задача — предсказание **Customer Lifetime Value (LTV)** на горизонте 30 дней. Особенности целевой переменной: данные сильно **zero-inflated**. Около 45.1% пользователей в обучающей выборке не совершают ни одной покупки ($\text{target} = 0$).

Публичный / Приватный лидерборд: 20% / 80%!

Оценка на публичном лидерборде вычисляется только по 50 000 из 250 000 клиентов. Это означает высокий риск *public-private shake-up*. Оптимизация моделей строилась на строгой локальной кросс-валидации (OOV) с последующей ортогональной оптимизацией весов ансамбля и масштабирующих множителей.

2. Эволюция признакового пространства и схема валидации

Для временных рядов использовался строго **Walk-Forward CV** ($\text{stride} = 14$ дней). Схема была расширена до **5 фолдов** ($\text{min_history} = 180$ дней) для построения устойчивого мета-ансамбля.

2.1. Исторические версии данных (v1 – v5)

- **v1–v2 (Базовые агрегации):** Сбор простых счетчиков действий и сумм. На этом этапе была допущена ошибка "машины времени" (утечка таргета в обучающие признаки), которая привела к ложно-оптимистичным результатам (до 1.69009) и была устранена в v3.
- **v3–v4 (RFM и временные окна):** Внедрение строгой Walk-Forward валидации. Расчет классических RFM-признаков (Recency, Frequency, Monetary) по окнам от 3 до 365 дней.
- **v5 (Взаимосвязи и тренды):** Добавление вторичных признаков, таких как конверсия из поиска в корзину и тренды отношения трат за 7 дней к 30 дням.

2.2. Финальная версия v6 (Data-Centric AI)

Сгенерировано 435 признаков. Ключевые нововведения, обеспечившие максимальный прирост метрики:

- **Межпокупочные паттерны:** mean/std gap между заказами, метрики регулярности ($\text{order_regularity_cv}$).
- **Lifecycle Trajectory:** Ускорение заказов ($\text{order_acceleration}$) и GMV slope.
- **Винзоризация таргета (Target Capping):** Ограничение целевой переменной на этапе обучения по 99.9-му перцентилю (4000) для защиты моделей от аномальных "китов".
- **Dormancy & Gaps:** Обработка пустых интервалов числом 999.0 с введением жестких флагов is_single_buyer и is_dormant (спячка > 120 дней).

3. Архитектура Мета-Ансамбля (Stacking)

Финальное решение построено на максимизации **независимости ошибок** (Error Orthogonality). Базовый ансамбль состоит из трех SOTA-моделей. В ходе сканирования (ternary search) весов на чистых данных v6 был подтвержден глобальный локальный оптимум (RMSLE = 1.65559) при распределении:

3.1. 1. CatBoostRegressor (Базовый фундамент, Вес: 70%)

Градиентный бустинг с *level-wise* (oblivious) построением деревьев. Применена техника **Seed Averaging**: усреднение предсказаний 5 моделей с разными seed-значениями для радикального снижения дисперсии.

3.2. 2. Tabular MLP + ZILN Loss (Вероятностная нейросеть, Вес: 20%)

Полносвязный 4-слойный перцептрон, обученный на сглаженных признаках через **QuantileTransformer**. Использует функцию потерь ZILN (*Zero-Inflated Lognormal Loss*), которая элегантно и одновременно решает задачи классификации и регрессии в едином пайплайне.

3.3. 3. XGBoost (Охотник на нелинейности, Вес: 10%)

Асимметричный градиентный бустинг с глубокой L1-регуляризацией (`reg_alpha = 2.0`).

4. Анализ преодоленных проблем

4.1. Взрыв градиентов MLP из-за StandardScaler

Применение классического **StandardScaler** привело к катастрофическому росту Loss. Проблема решена переходом на **QuantileTransformer** (`output_distribution='normal'`), который аккуратно уложил все выбросы в гауссиану.

4.2. Сезонный сдвиг (Concept Drift) и Праздничные множители

Тестовая выборка представляет собой период с 14 февраля по 15 марта (весенние праздники). Модель, обученная на среднегодовых паттернах, систематически недооценивала траты. Аналитика по историческим данным 2025 года показала рост конверсии в праздничный месяц на 3% (итоговый мультипликатор ≈ 1.09).

Применение масштабирующего множителя (до 1.12375) к предсказаниям финального ансамбля позволило пробить потолок чистых моделей и достичь феноменального RMSLE **1.65305**.

5. Отклоненные гипотезы и стратегии

В процессе разработки был протестирован и отвергнут ряд подходов (см. таблицу сабмитов):

- **Tweedie Loss:** Классическая функция потерь для zero-inflated распределений. Эксперименты с Tweedie в бустингах показали результаты хуже, чем стандартная оптимизация RMSE на логарифмированном таргете $\log(1 + y)$ или использование кастомного ZILN в MLP.
- **Two-Stage Pipeline (Двухэтапная модель):** Идея отдельного обучения бинарного классификатора ($P(y > 0)$) и регрессора для покупателей. Была отклонена, так как MLP с ZILN-loss решает эту задачу математически точнее внутри единой архитектуры (совместное обучение p и μ), предотвращая накопление ошибки (error compounding) между моделями.
- **Псевдо-разметка (Pseudo-Labeling):** Эксперимент с добавлением предсказаний с тестовой выборки в тренировочный сет был свернут из-за высокого риска жесткого переобучения на публичный лидерборд (учитывая сплит 20% / 80%, доверять паблику на 100% было опасно).
- **Эмбединги Event2Vec (Look-ahead bias):** Обучение Word2Vec на всей истории без строгой Walk-Forward изоляции приводило к заглядыванию в будущее. Честная изоляция эмбедингов внутри фолдов не дала ожидаемого буста метрики из-за высокой разреженности последовательностей покупок.
- **Вероятностные модели BTYD (Buy Till You Die):** Модели вроде BG/NBD показали крайне слабую способность предсказывать LTV на коротком горизонте (30 дней) для наших данных ($\text{RMSLE} > 1.76$).
- **Логарифмический блендинг:** Усреднение логарифмов предсказаний (геометрическое среднее) слишком сильно занижало прогнозы для крупных покупателей по сравнению с классическим арифметическим усреднением.

6. Полная история сабмитов (Leaderboard)

Ниже задокументированы все 68 отправленных решений, отсортированные от лучшей метрики к худшей.

Таблица 1: Часть 1: Чемпионы и финальные тюнинги (Топ-24)

Имя файла	RMSLE	Примечание
v6_champion_mult_1.12375.csv	1.65305	Абсолютный оптимум (Множитель 1.12375)
v6_champion_mult_1.125.csv	1.65305	Бинарный поиск множителя
v6_champion_mult_1.1225.csv	1.65305	Бинарный поиск множителя
v6_champion_mult_1.12.csv	1.65306	Разведка правой границы
v6_champion_mult_1.13.csv	1.65306	Разведка правой границы
v6_champion_mult_1.14.csv	1.65309	Подтверждение экстремума
v6_champion_mult_1.10.csv	1.65313	Приближение к дну
v6_champion_mult_1.09.csv	1.65321	Расчетный сдвиг 2025 года
v6_champion_mult_1.05.csv	1.65389	Успешный старт калибровки
v6_champion_mult_1.03.csv	1.65445	
v6_champion_mult_1.02.csv	1.65479	
v6_arithmetic_cb70_mlp20_xgb10	1.65559	Лучший чистый базовый ансамбль
v6_arithmetic_cb65_mlp25_xgb10	1.65566	Тест увеличенной доли MLP
v6_arithmetic_cb65_mlp20_xgb15	1.65568	Тест увеличенной доли XGBoost
v6_arithmetic_cb75_mlp15_xgb10	1.65574	
arithmetic_cb75_mlp15_xgb10.csv	1.65581	
arithmetic_cb75_mlp20_xgb05.csv	1.65584	
FINAL_blend_cb80_mlp15_xgb05	1.65590	
arithmetic_cb85_mlp10_xgb05.csv	1.65601	
FINAL_blend_cb85_mlp15.csv	1.65605	
v6_champion_mult_0.98.csv	1.65655	Ухудшение (занижение прогноза)
catboost_v5_seed_avg.csv	1.65656	
catboost_v6_seed_avg.csv	1.65678	Соло CatBoost (v6)
v6_champion_mult_0.97.csv	1.65710	

Таблица 2: Часть 2: Поиск базового ансамбля и эксперименты (25–46)

Имя файла	RMSLE	Примечание
blend_seed_avg_92_rnn8.csv	1.65878	Бывший лидер (v4b + RNN)
blend_seed_avg_90_rnn10.csv	1.65884	
blend_seed_avg_95_rnn5.csv	1.65890	
frank_cb70_ziln20_xgb5_rnn5.csv	1.65912	
frank_cb75_ziln20_rnn5.csv	1.65912	Эксперимент с pseudo-labeling
blend_pseudo_90_rnn10.csv	1.65929	
blend_ortho_90_10.csv	1.65935	
logblend_cb800_mlp150_xgb50.csv	1.65975	
frank_cb70_ziln15_rnn15.csv	1.65977	Отказ от Log-Space блендинга
catboost_v4a_seed_avg.csv	1.65984	
blend_ortho_85_15.csv	1.65992	
ziln_v6_v1_submission.csv	1.66008	
catboost_v4a_baseline_sub...	1.66049	Рекорд соло-нейросети ZILN (v6)
blend_v4a_ortho_95_05.csv	1.66071	
blend_v4a_ortho_90_10.csv	1.66113	
ziln_v5_v1_submission.csv	1.66220	
catboost_v5_seed_avg.csv	1.66265	Оверфит Optuna
blend_v4a60_lgbm40.csv	1.66336	
xgboost_v6_submission.csv	1.66478	Соло XGBoost (v6)
xgboost_v5_submission.csv	1.66506	
mlp_ziln_submission.csv	1.66545	Baseline от организаторов
catboost_baseline_submission	1.67028	

Таблица 3: Часть 3: Ранние версии, утечки и бейзлайны (47–68)

Имя файла	RMSLE	Примечание
xgboost_log_submission.csv	1.67102	
lgbm_v3_submission.csv	1.67115	
catboost_v3_submission.csv	1.67116	
catboost_v4_cumul_sub...	1.67126	
catboost_v4_single_sub...	1.67177	
blend_cbv3_80_rnnv3_19.csv	1.67380	
blend_cbv3_70_rnnv3_30.csv	1.67583	
ensemble_cb70_rnn30.csv	1.67588	
blend_cbv3_65_rnnv3_35.csv	1.67702	
lgbm_v4_submission.csv	1.68433	Нестабильность LightGBM
ensemble_v2_cb70_rnn30.csv	1.68803	Утечка данных в v2
ensemble_v2_cb60_rnn40.csv	1.68942	Утечка данных в v2
catboost_v2_submission.csv	1.69009	Утечка данных в v2
lgbm_v4_submission.csv	1.70118	
rnn_v4_submission.csv	1.70489	Соло RNN (v4)
rnn_v2_submission.csv	1.71792	
catboost_v4a_zero_hacked	1.73573	Провал гипотезы жестких нулей
rnn_baseline_submission.csv	1.73624	
btyd_blend_btyd2_cb8.csv	1.76655	Провал вероятностной модели BTYD
catboost_tuned_submission	1.79400	Провал поиска параметров Optuna v1
btyd_blend_btyd3_cb7.csv	1.81827	
rnn_v4_submission.csv	1.87947	Критическая ошибка/утечка таргета