

Технический отчёт

Предсказание LTV пользователей

Хакатон по машинному обучению

Задача: Предсказание суммарного GMV пользователей за 30 дней
на основе обезличенных данных активности в Поиске и Каталоге

Участник:	Кирилл Егоров
Метрика:	RMSLE (Root Mean Squared Log Error)
Данные:	250 000 пользователей, 01.01.2025–13.02.2026
Финальный ЛБ:	1.65305 (CB 70% + MLP 20% + XGB 10% $\times$ 1.12375)
GPU:	NVIDIA RTX 4050 Laptop (6 ГБ VRAM)

Дата составления: 28 августа 2026 г.

Содержание

1	Теоретический базис и математическая модель	1
1.1	Нейросетевая модель: Tabular MLP и ZILN	1
1.2	Градиентный бустинг: CatBoost и XGBoost	1
2	Архитектура решения и инженерия признаков	2
2.1	Схема валидации и алгоритмы стабилизации	2
2.2	Конвейер генерации признаков (Feature Engineering)	2
3	Успешные исследования и тестирование гипотез	2
4	Анализ отвергнутых гипотез	3
5	Валидация пайплайна и результаты	3

1. Теоретический базис и математическая модель

Оценка качества предсказаний Customer Lifetime Value (LTV) производится с помощью логарифмической метрики Root Mean Squared Logarithmic Error (RMSLE). Фундаментальная сложность заключается в смешанном (Zero-Inflated) распределении целевой переменной: порядка 46.4% пользователей в выборке не совершают ни одной транзакции в прогнозном окне (`target = 0`) [2].

1.1. Нейросетевая модель: Tabular MLP и ZILN

Для корректного моделирования нулевых и положительных трат была разработана вероятностная архитектура с применением функции потерь **Zero-Inflated LogNormal (ZILN)**. Сеть аппроксимирует три логита $\mathbf{z} = (z_0, z_1, z_2)$, которые трансформируются в параметры распределения [2]:

$$p = \frac{1}{1 + \exp(-z_0)}, \quad \mu = z_1, \quad \sigma = \log(1 + \exp(z_2))$$

Итоговая функция потерь объединяет бинарную кросс-энтропию (BCE) и негативное логарифмическое правдоподобие (NLL) [5, 2]:

$$\mathcal{L} = -\mathbb{I}_{y=0} \log(1 - p) - \mathbb{I}_{y>0} \left[\log(p) - \frac{\log(\sigma\sqrt{2\pi}) + (\log y - \mu)^2}{2\sigma^2} \right]$$

Для извлечения финального предсказания применена эмпирически выведенная формула, напрямую минимизирующая логарифмический штраф метрики хакатона [2]:

$$\hat{y} = \exp(p \cdot \mu) - 1$$

1.2. Градиентный бустинг: CatBoost и XGBoost

Обе древовидные модели оптимизировались под метрику RMSE на предварительно логарифмированном таргете $\tilde{y}_i = \log(1 + y_i)$ [2].

CatBoost использует симметричные (oblivious) деревья решений, где один и тот же предикат расщепления применяется ко всему уровню дерева [6]. Итоговый прогноз формируется суммированием весов листьев:

$$F(x) = \sum_{k=1}^K c_k \mathbb{I}(x \in R_k)$$

XGBoost строит несимметричные деревья, применяя алгоритм гистограммного поиска сплитов. Применяется строгая оптимизация с L_1 (α) и L_2 (λ) регуляризацией листьев w_k [7, 2]:

$$\mathcal{L}_{\text{XGB}} = \sum_{i=1}^N \frac{1}{2} (\tilde{y}_i - \hat{y}_i)^2 + \sum_{k=1}^K \left(\gamma T_k + \frac{1}{2} \lambda \|w_k\|^2 + \alpha \|w_k\|_1 \right)$$

В пайплайне заданы веса $\alpha = 2.0, \lambda = 5.0$, что жестко штрафует сложные деревья и выявляет скрытые нелинейные паттерны [2].

2. Архитектура решения и инженерия признаков

2.1. Схема валидации и алгоритмы стабилизации

Для исключения эффекта «заглядывания в будущее» реализован алгоритм **Walk-Forward Cross-Validation** [1]. Анкорная дата t_{anchor} последовательно сдвигается на шаг S (14 дней), формируя независимые обучающие и валидационные блоки:

$$\text{Train}_k = \{(x_i, y_i) \mid t_i \in [t_{\text{anchor}}^{(k)} - H, t_{\text{anchor}}^{(k)}]\}$$

$$\text{Val}_k = \{(x_i, y_i) \mid t_i \in [t_{\text{anchor}}^{(k)} + 1, t_{\text{anchor}}^{(k)} + 30]\}$$

где H — глубина исторического окна (180 дней) [1].

Для снижения дисперсии градиентного бустинга применена техника **Seed Averaging**. Итоговый прогноз базовой модели CatBoost $\hat{y}_{\text{CB}}$ формируется как арифметическое среднее предсказаний 5 моделей, обученных с различными седами [2]:

$$\hat{y}_{\text{CB}}(x) = \frac{1}{5} \sum_{m=1}^5 F_m(x; \text{seed}_m)$$

2.2. Конвейер генерации признаков (Feature Engineering)

На базе библиотеки **Polars** реализована генерация 437 признаков [1].

- **Lifecycle Trajectory:** Отношение трат за последовательные периоды позволило вычислить метрики ускорения заказов (`order_acceleration`):

$$\text{Accel} = \frac{\text{Ord}_{w1} + \epsilon}{\text{Ord}_{w2} + \epsilon} - \frac{\text{Ord}_{w3} + \epsilon}{\text{Ord}_{w4} + \epsilon}$$

- **Межпокупочные интервалы (Gaps):** Расчет математического ожидания (`mean_order_gap`) и стандартного отклонения (`std_order_gap`). Коэффициент вариации σ/μ (`order_regularity_cv`) позволил оценивать стабильность спроса. Пустые интервалы заполнялись значением 999.0 [1].
- **Индикация оттока:** Созданы бинарные флаги `is_single_buyer` и `is_dormant`. Последний активируется для пользователей без покупок более 120 дней [1].
- **Винзоризация таргета (Target Capping):** Целевая переменная жестко ограничивалась по 99.9-му перцентилю (4000.0) для защиты градиентов от аномальных «китов» [1].

3. Успешные исследования и тестирование гипотез

1. Опровержение гипотезы отдельных моделей (Two-Stage Pipeline). Обучение отдельного бинарного классификатора и регрессора приводило к перемножению ошибок моделей. Внедрение единой нейросети (Tabular MLP) с функцией ZILN

Loss математически корректно связало вероятности p и μ на уровне градиентов, что дало значительный прирост OOF-метрики [2].

2. Трансформация признакового пространства. Использование `StandardScaler` приводило к коллапсу нейросети из-за выбросов. Переход на `QuantileTransformer` жестко нормализовал все признаки в идеальную гауссиану в границах $[-5.0, 5.0]$, обеспечив стабильную сходимость [2].

3. Выявление сезонного сдвига (Seasonal Concept Drift). Анализ исторических логов показал, что тестовая выборка (14.02 - 15.03) подвержена весенней сезонности. По данным 2025 года конверсия в этот месяц росла с 37.23% до 40.29%, а средний чек с 59.53 до 59.97 [3]. Был рассчитан теоретический мультипликатор 1.0901, который в ходе бинарного поиска был уточнен до эмпирического оптимума 1.12375 [3].

4. Анализ отвергнутых гипотез

Опираясь на историю отправок (раздел 5), ряд подходов был классифицирован как математически или алгоритмически неэффективный для текущей задачи [4]:

- **Вероятностные BTYD-модели (Buy Till You Die):** Классические модели (BG/NBD) показали полную неспособность прогнозировать LTV на коротком 30-дневном горизонте. Сабмиты `btyd_blend_...` продемонстрировали худшие результаты ($\text{RMSLE} > 1.76$) [4].
- **Логарифмический блендинг (Log-Space Blending):** Геометрическое усреднение предсказаний (`logblend_...`) слишком сильно пессимизировало прогнозы для крупных покупателей, уступив линейному арифметическому бленду ($\text{RMSLE} 1.65975$) [4].
- **Псевдо-разметка (Pseudo-labeling):** Интеграция тестовых предсказаний обратно в тренировочный сет (`blend_pseudo_...`) привела к жесткому переобучению на Public LB и ухудшению метрики [4].
- **Автоматический тюнинг (Optuna):** Поиск гиперпараметров (`catboost_tuned_...`) вызвал переобучение на валидационной выборке ($\text{RMSLE} 1.79400$). Ручной подбор с глубокой регуляризацией оказался стабильнее [4].
- **Принудительное обнуление (Zero-hacked):** Эвристическое зануление прогнозов для «спящих» пользователей (`catboost_v4a_zero_hacked`) нарушило калибровку логнормального распределения и уронило метрику до 1.73573 [4].

5. Валидация пайплайна и результаты

Для финального решения использовался арифметический блендинг предсказаний с весами, оптимизированными для достижения максимальной ортогональности (независимости) ошибок [2]:

- **CatBoost (70%)**: Стабильный базовый прогноз (OOF RMSLE: 1.66115).
- **Tabular MLP ZILN (20%)**: Сглаживает нулевых покупателей (OOF RMSLE: 1.66912).
- **XGBoost (10%)**: Корректировщик нелинейностей (OOF RMSLE: 1.64183).

Итоговый бленд без масштабирования показал OOF RMSLE 1.65559, а применение сезонного множителя 1.12375 вывело решение на финальный скор **1.65305** [3, 4]. Ниже представлена полная эволюция качества пайплайна.

Таблица 1: Часть 1: Чемпионы и финальные тюнинги (Топ-24)

Имя файла	RMSLE	Примечание
v6_champion_mult_1.12375.csv	1.65305	Абсолютный оптимум (Множитель 1.12375)
v6_champion_mult_1.125.csv	1.65305	Бинарный поиск множителя
v6_champion_mult_1.1225.csv	1.65305	Бинарный поиск множителя
v6_champion_mult_1.12.csv	1.65306	Разведка правой границы
v6_champion_mult_1.13.csv	1.65306	Разведка правой границы
v6_champion_mult_1.14.csv	1.65309	Подтверждение экстремума
v6_champion_mult_1.10.csv	1.65313	Приближение к дну
v6_champion_mult_1.09.csv	1.65321	Расчетный сдвиг 2025 года
v6_champion_mult_1.05.csv	1.65389	Успешный старт калибровки
v6_champion_mult_1.03.csv	1.65445	
v6_champion_mult_1.02.csv	1.65479	
v6_arithmetic_cb70_mlp20_xgb10	1.65559	Лучший чистый базовый ансамбль
v6_arithmetic_cb65_mlp25_xgb10	1.65566	Тест увеличенной доли MLP
v6_arithmetic_cb65_mlp20_xgb15	1.65568	Тест увеличенной доли XGBoost
v6_arithmetic_cb75_mlp15_xgb10	1.65574	
arithmetic_cb75_mlp15_xgb10.csv	1.65581	
arithmetic_cb75_mlp20_xgb05.csv	1.65584	
FINAL_blend_cb80_mlp15_xgb05	1.65590	
arithmetic_cb85_mlp10_xgb05.csv	1.65601	
FINAL_blend_cb85_mlp15.csv	1.65605	
v6_champion_mult_0.98.csv	1.65655	Ухудшение (занижение прогноза)
catboost_v5_seed_avg.csv	1.65656	
catboost_v6_seed_avg.csv	1.65678	Соло CatBoost (v6)
v6_champion_mult_0.97.csv	1.65710	

Таблица 2: Часть 2: Поиск базового ансамбля и эксперименты (25–46)

Имя файла	RMSLE	Примечание
blend_seed_avg_92_rnn8.csv	1.65878	Бывший лидер (v4b + RNN)
blend_seed_avg_90_rnn10.csv	1.65884	
blend_seed_avg_95_rnn5.csv	1.65890	
frank_cb70_ziln20_xgb5_rnn5.csv	1.65912	
frank_cb75_ziln20_rnn5.csv	1.65912	
blend_pseudo_90_rnn10.csv	1.65929	Эксперимент с pseudo-labeling
blend_ortho_90_10.csv	1.65935	
logblend_cb800_mlp150_xgb50.csv	1.65975	Отказ от Log-Space блендинга
frank_cb70_ziln15_rnn15.csv	1.65977	
catboost_v4a_seed_avg.csv	1.65984	Рекорд соло-нейросети ZILN (v6)
blend_ortho_85_15.csv	1.65992	
ziln_v6_v1_submission.csv	1.66008	
catboost_v4a_baseline_sub...	1.66049	
blend_v4a_ortho_95_05.csv	1.66071	
blend_v4a_ortho_90_10.csv	1.66113	Оверфит Optuna
ziln_v5_v1_submission.csv	1.66220	
catboost_v5_seed_avg.csv	1.66265	
blend_v4a60_lgbm40.csv	1.66336	
xgboost_v6_submission.csv	1.66478	
xgboost_v5_submission.csv	1.66506	Соло XGBoost (v6)
mlp_ziln_submission.csv	1.66545	
catboost_baseline_submission	1.67028	Baseline от организаторов

Таблица 3: Часть 3: Ранние версии, утечки и бейзлайны (47–68)

Имя файла	RMSLE	Примечание
xgboost_log_submission.csv	1.67102	
lgbm_v3_submission.csv	1.67115	
catboost_v3_submission.csv	1.67116	
catboost_v4_cumul_sub...	1.67126	
catboost_v4_single_sub...	1.67177	
blend_cbv3_80_rnnv3_19.csv	1.67380	
blend_cbv3_70_rnnv3_30.csv	1.67583	
ensemble_cb70_rnn30.csv	1.67588	
blend_cbv3_65_rnnv3_35.csv	1.67702	
lgbm_v4_submission.csv	1.68433	Нестабильность LightGBM
ensemble_v2_cb70_rnn30.csv	1.68803	Утечка данных в v2
ensemble_v2_cb60_rnn40.csv	1.68942	Утечка данных в v2
catboost_v2_submission.csv	1.69009	Утечка данных в v2
lgbm_v4_submission.csv	1.70118	
rnn_v4_submission.csv	1.70489	Соло RNN (v4)
rnn_v2_submission.csv	1.71792	
catboost_v4a_zero_hacked	1.73573	Провал гипотезы жестких нулей
rnn_baseline_submission.csv	1.73624	
btvd_blend_btyd2_cb8.csv	1.76655	Провал вероятностной модели BTYD
catboost_tuned_submission	1.79400	Провал поиска параметров Optuna v1
btvd_blend_btyd3_cb7.csv	1.81827	
rnn_v4_submission.csv	1.87947	Критическая ошибка/утечка таргета

Список литературы

- [1] Егоров К., *1_data_v6.ipynb*: Инженерия признаков и Walk-Forward валидация, 2026.
- [2] Егоров К., *2_train_blend_v6.ipynb*: Архитектура CatBoost, XGBoost, ZILN MLP и алгоритмы блендинга, 2026.
- [3] Егоров К., *3_extra_tests.ipynb*: Расчет сезонного сдвига (Concept Drift) и постобработка, 2026.
- [4] Егоров К., *Отчёт по хакатону: LTV-предсказание (report_2.pdf)*, 2026.
- [5] Google, *Lifetime Value Library*, GitHub Repository, 2020. Доступно по адресу: https://github.com/google/lifetime_value
- [6] Prokhorenkova, L., Gusev, G., Vorobev, A., Dorogush, A. V., & Gulin, A. (2018). *CatBoost: unbiased boosting with categorical features*. Advances in neural information processing systems, 31.
- [7] Chen, T., & Guestrin, C. (2016). *XGBoost: A scalable tree boosting system*. In Proceedings of the 22nd acm sigkdd international conference on knowledge discovery and data mining (pp. 785-794).