

Технический отчёт

Предсказание LTV пользователей

Хакатон по машинному обучению

Задача: Предсказание суммарного GMV пользователей за 30 дней
на основе обезличенных данных активности в Поиске и Каталоге

Участник:	Кирилл Егоров
Метрика:	RMSLE (Root Mean Squared Log Error)
Tie-breaker:	Gini по предсказаниям + RMSPE суммарного GMV
Данные:	250 000 пользователей, 01.01.2025–13.02.2026
Финальный ЛБ:	1.65306 (CB 70% + MLP 20% + XGB 10% $\times 1.12$)
Публичный ЛБ:	20% (50 000 клиентов)
Приватный ЛБ:	80% (200 000 клиентов)
Старт:	10 августа 2026 г.
Дедлайн:	$\approx$ 31 августа 2026 г.
Лимит:	5 сабмитов / день, 2 финальных решения
GPU:	NVIDIA RTX 4050 Laptop (6 ГБ VRAM)

Содержание

1	Описание задачи и данных	1
2	Схема валидации и Признаковое пространство (v6)	1
3	Архитектура Мета-Ансамбля (Stacking)	1
3.1	1. CatBoostRegressor (Базовый фундамент, Вес: 70%)	1
3.2	2. Tabular MLP + ZILN Loss (Вероятностная нейросеть, Вес: 20%) . . .	2
3.3	3. XGBoost (Охотник на нелинейности, Вес: 10%)	2
4	Анализ преодоленных проблем	2
4.1	Взрыв градиентов MLP из-за StandardScaler	2
4.2	Сезонный сдвиг (Concept Drift) и Праздничные множители	2
5	Отклоненные гипотезы и стратегии	2
6	Полная история сабмитов (Leaderboard)	3

1. Описание задачи и данных

Задача — предсказание **Customer Lifetime Value (LTV)** на горизонте 30 дней. Особенности целевой переменной: данные сильно **zero-inflated**. Около 45.1% пользователей в обучающей выборке не совершают ни одной покупки ($\text{target} = 0$).

Публичный / Приватный лидерборд: 20% / 80%!

Оценка на публичном лидерборде вычисляется только по 50 000 из 250 000 клиентов. Это означает высокий риск *public-private shake-up*. Оптимизация моделей строилась на строгой локальной кросс-валидации (OOV) с последующей ортогональной оптимизацией весов ансамбля и масштабирующих множителей.

2. Эволюция признакового пространства и схема валидации

Для временных рядов использовался строго **Walk-Forward CV** ($\text{stride} = 14$ дней). Схема была расширена до **5 фолдов** ($\text{min_history} = 180$ дней) для построения устойчивого мета-ансамбля.

2.1. Исторические версии данных (v1 – v5)

- **v1–v2 (Базовые агрегации)**: Сбор простых счетчиков действий и сумм. На этом этапе была допущена ошибка "машины времени" (утечка таргета в обучающие признаки), которая привела к ложно-оптимистичным результатам (до 1.69009) и была устранена в v3.
- **v3–v4 (RFM и временные окна)**: Внедрение строгой Walk-Forward валидации. Расчет классических RFM-признаков (Recency, Frequency, Monetary) по окнам от 3 до 365 дней.
- **v5 (Взаимосвязи и тренды)**: Добавление вторичных признаков, таких как конверсия из поиска в корзину и тренды отношения трат за 7 дней к 30 дням.

2.2. Финальная версия v6 (Data-Centric AI)

Сгенерировано 435 признаков. Ключевые нововведения, обеспечившие максимальный прирост метрики:

- **Межпокупочные паттерны**: mean/std gap между заказами, метрики регулярности ($\text{order_regularity_cv}$).
- **Lifecycle Trajectory**: Ускорение заказов ($\text{order_acceleration}$) и GMV slope.
- **Винзоризация таргета (Target Capping)**: Ограничение целевой переменной на этапе обучения по 99.9-му перцентилю (4000) для защиты моделей от аномальных "китов".
- **Dormancy & Gaps**: Обработка пустых интервалов числом 999.0 с введением жестких флагов is_single_buyer и is_dormant (спячка > 120 дней).

3. Архитектура Мета-Ансамбля (Stacking)

Финальное решение построено на максимизации **независимости ошибок** (Error Orthogonality). Базовый ансамбль состоит из трех SOTA-моделей. В ходе сканирования (ternary search) весов на чистых данных v6 был подтвержден глобальный локальный оптимум ($\text{RMSLE} = 1.65559$) при распределении:

3.1. 1. CatBoostRegressor (Базовый фундамент, Вес: 70%)

Градиентный бустинг с *level-wise* (oblivious) построением деревьев. Применена техника **Seed Averaging**: усреднение предсказаний 5 моделей с разными seed-значениями для радикального снижения дисперсии.

3.2. 2. Tabular MLP + ZILN Loss (Вероятностная нейросеть, Вес: 20%)

Полносвязный 4-слойный перцептрон, обученный на сглаженных признаках через **QuantileTransformer**. Использует функцию потерь **ZILN** (*Zero-Inflated Lognormal Loss*), которая элегантно и одновременно решает задачи классификации и регрессии в едином пайплайне.

3.3. 3. XGBoost (Охотник на нелинейности, Вес: 10%)

Асимметричный градиентный бустинг с глубокой L1-регуляризацией ($\text{reg_alpha} = 2.0$).

4. Анализ преодоленных проблем

4.1. Взрыв градиентов MLP из-за StandardScaler

Применение классического **StandardScaler** привело к катастрофическому росту Loss. Проблема решена переходом на **QuantileTransformer** ($\text{output_distribution} = \text{'normal'}$), который аккуратно уложил все выбросы в гауссиану.

4.2. Сезонный сдвиг (Concept Drift) и Праздничные множители

Тестовая выборка представляет собой период с 14 февраля по 15 марта (весенние праздники). Модель, обученная на среднегодовых паттернах, систематически недооценивала траты. Аналитика по историческим данным 2025 года показала рост конверсии в праздничный месяц на 3% (итоговый мультипликатор ≈ 1.09).

Применение масштабирующего множителя (до 1.12) к предсказаниям финального ансамбля позволило пробить потолок чистых моделей и достичь феноменального **RMSLE 1.65306**.

5. Отклоненные гипотезы и стратегии

В процессе разработки был протестирован и отвергнут ряд подходов (см. таблицу сабмитов):

- **Tweedie Loss:** Классическая функция потерь для zero-inflated распределений. Эксперименты с Tweedie в бустингах показали результаты хуже, чем стандартная оптимизация RMSE на логарифмированном таргете $\log(1 + y)$ или использование кастомного ZILN в MLP.
- **Two-Stage Pipeline (Двухэтапная модель):** Идея отдельного обучения бинарного классификатора ($P(y > 0)$) и регрессора для покупателей. Была отклонена, так как MLP с ZILN-loss решает эту задачу математически точнее внутри единой архитектуры (совместное обучение p и μ), предотвращая накопление ошибки (error compounding) между моделями.
- **Псевдо-разметка (Pseudo-Labeling):** Эксперимент с добавлением предсказаний с тестовой выборки в тренировочный сет был свернут из-за высокого риска жесткого переобучения на публичный лидерборд (учитывая сплит 20% / 80%, доверять паблику на 100% было опасно).
- **Эмбединги Event2Vec (Look-ahead bias):** Обучение Word2Vec на всей истории без строгой Walk-Forward изоляции приводило к заглядыванию в будущее. Честная изоляция эмбедингов внутри фолдов не дала ожидаемого буста метрики из-за высокой разреженности последовательностей покупок.
- **Вероятностные модели BTYD (Buy Till You Die):** Модели вроде BG/NBD показали крайне слабую способность предсказывать LTV на коротком горизонте (30 дней) для наших данных ($\text{RMSLE} > 1.76$).
- **Логарифмический блендинг:** Усреднение логарифмов предсказаний (геометрическое среднее) слишком сильно занижало прогнозы для крупных покупателей по сравнению с классическим арифметическим усреднением.

6. Полная история сабмитов (Leaderboard)

В таблицах ниже задокументированы все итерации отправок, отсортированные по улучшению метрики (от лучших к худшим).

Таблица 1: Полная история результатов (Часть 1: Чемпионы и Топ-бленды)

Имя файла (модель / бленд)	RMSLE	Примечание
v6_champion_mult_1.12.csv	1.65306	Абсолютный чемпион (Множитель 1.12)
v6_champion_mult_1.10.csv	1.65313	Близость к глобальному экстремуму
v6_champion_mult_1.09.csv	1.65321	Расчетный сезонный сдвиг (2025 год)
v6_champion_mult_1.05.csv	1.65389	Пробой через калибровку пост-процессинга
v6_champion_mult_1.03.csv	1.65445	
v6_champion_mult_1.02.csv	1.65479	Начало разведывательного поиска
v6_arithmetic_cb70_mlp20_xgb10	1.65559	Лучший чистый базовый ансамбль
v6_arithmetic_cb65_mlp25_xgb10	1.65566	Проверка гипотезы усиления нейросети
v6_arithmetic_cb65_mlp20_xgb15	1.65568	Проверка гипотезы усиления XGBoost
v6_arithmetic_cb75_mlp15_xgb10	1.65574	Осторожный бленд v6
arithmetic_cb75_mlp15_xgb10.csv	1.65581	Промежуточный бленд v5
FINAL_blend_cb80_mlp15_xgb05	1.65590	
FINAL_blend_cb85_mlp15.csv	1.65605	Двуглавый бленд v5
v6_champion_mult_0.98.csv	1.65655	Ухудшение из-за занижения прогноза
catboost_v5_seed_avg.csv	1.65656	
catboost_v6_seed_avg.csv	1.65678	Соло CatBoost на данных v6
v6_champion_mult_0.97.csv	1.65710	Ухудшение из-за занижения прогноза
blend_seed_avg_92_rnn8.csv	1.65878	Бывший чемпион (v4b + RNN v2)
blend_seed_avg_90_rnn10.csv	1.65884	
frank_cb70_ziln20_xgb5_rnn5	1.65912	Промежуточный бленд (v4)
blend_pseudo_90_rnn10.csv	1.65929	Эксперимент с псевдо-разметкой
logblend_cb800_mlp150_xgb50.csv	1.65975	Отказ от Log-Space блендинга
catboost_v4a_seed_avg.csv	1.65984	Базовый CatBoost v4 (Seed Avg)
ziln_v6_v1_submission.csv	1.66008	Рекорд соло-нейросети (данные v6)
catboost_v5_seed_avg.csv	1.66265	Оверфит на валидации через Optuna

Таблица 2: Полная история результатов (Часть 2: Остальные отправки и Базлайны)

Имя файла (модель / бленд)	RMSLE	Примечание
xgboost_v6_submission.csv	1.66478	
xgboost_v5_submission.csv	1.66506	XGBoost с логарифмированным таргетом
mlp_ziln_submission.csv	1.66545	MLP ZILN на v4 фичах
catboost_baseline_sub.csv	1.67028	Baseline v1 (от организаторов)
xgboost_log_submission.csv	1.67102	XGBoost v4
lgbm_v3_submission.csv	1.67115	
catboost_v3_submission.csv	1.67116	
blend_cbv3_80_rnnv3_19.csv	1.67380	
ensemble_cb70_rnn30.csv	1.67588	
lgbm_v4_submission.csv	1.68433	Нестабильность LGBM
ensemble_v2_cb70_rnn30.csv	1.68803	Утечка v2
catboost_v2_submission.csv	1.69009	Утечка v2
rnn_v4_submission.csv	1.70489	Соло RNN v4
catboost_v4a_zero_hacked.csv	1.73573	Провал гипотезы жестких нулей
rnn_baseline_sub.csv	1.73624	
btyd_blend_btyd2_cb8.csv	1.76655	Провал вероятностной модели (BTYD)
catboost_tuned_submission.csv	1.79400	Провал Optuna v1
rnn_v4_submission.csv	1.87947	Утечка таргета