

Технический отчёт

Предсказание LTV пользователей

Хакатон по машинному обучению

Задача: Предсказание суммарного GMV пользователей за 30 дней
на основе обезличенных данных активности в Поиске и Каталоге

Участник:	Кирилл Егоров
Метрика:	RMSLE (Root Mean Squared Log Error)
Tie-breaker:	Gini по предсказаниям + RMSPE суммарного GMV
Данные:	250 000 пользователей, 01.01.2025–13.02.2026
Текущий ЛБ:	1.65935 (Blend CB v4a + RNN v2)
Публичный ЛБ:	20% (50 000 клиентов)
Приватный ЛБ:	80% (200 000 клиентов)
Старт:	10 августа 2026 г.
Дедлайн:	≈ 31 августа 2026 г.
Лимит:	5 сабмитов / день, 2 финальных решения
GPU:	NVIDIA RTX 4050 Laptop (6 ГБ VRAM)

Содержание

1	Описание задачи и данных	1
1.1	Постановка задачи	1
1.2	Особенности исходных данных	1
2	Схема валидации: Walk-Forward Cross-Validation	1
3	Эволюция признакового пространства	1
4	Базовые алгоритмы и финальные эксперименты	1
4.1	CatBoostRegressor (Основа решения)	2
4.2	Рекуррентная нейронная сеть (PyTorch GRU)	2
5	Анализ неудачных подходов	2
5.1	Отказ от Tweedie Loss	2
5.2	Отказ от LightGBM	2
5.3	Парадокс ортогональности ансамблей	2
6	Ожидающие отправки решения (План на день)	2
7	Стратегия: Жёсткое ансамблирование	3

1. Описание задачи и данных

1.1. Постановка задачи

Задача — предсказание **Customer Lifetime Value (LTV)** на горизонте 30 дней. Модель должна по истории активности пользователя предсказать суммарный GMV за период с 14.02.2026 по 15.03.2026.

Публичный / Приватный лидерборд: 20% / 80%!

Оценка на публичном лидерборде вычисляется только по 50 000 из 250 000 клиентов. Это означает высокий риск *public-private shake-up*.

Метрика качества:

$$\text{RMSLE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (\log(1 + \hat{y}_i) - \log(1 + y_i))^2}$$

1.2. Особенности исходных данных

Особенности целевой переменной: данные сильно **zero-inflated**. Около 45.1% пользователей в обучающей выборке не совершают ни одной покупки ($\text{target} = 0$).

2. Схема валидации: Walk-Forward Cross-Validation

Для временных рядов используется строго **Walk-Forward CV**. Сравнивались схемы **Single-Fold** и **Cumulative**. Параметр **stride** (шаг смещения) критически влияет на качество. Оптимальным решением признан $\text{stride} = 14$ при Single-Fold обучении.

3. Эволюция признакового пространства

В итерации **v4** были применены следующие принципы:

1. **Окна полной истории:** добавлены агрегации за 270d и 365d (использование всей истории в 407 дней).
2. **Новые срезы:** `gmV_search`, `gmV_cat`, бинарные флаги `search/cat`.
3. **RFM-метрики:** добавлены `frequency` и `recency` (`recency_cart_days`, `user_age_days`).

4. Базовые алгоритмы и финальные эксперименты

4.1. CatBoostRegressor (Основа решения)

Градиентный бустинг с *level-wise* построением деревьев на 392 признаках v4. **Эксперимент Seed Averaging:** Для устранения дисперсии лучшая конфигурация была обучена 5 раз с различными seed-значениями (42, 123, 777, 2024, 31415) и пониженным $lr = 0.015$. Усреднение предиктов (CatBoost v4b) снизило RMSLE на локальной валидации с 1.66332 до 1.66297.

4.2. Рекуррентная нейронная сеть (PyTorch GRU)

RNN учитывает секвенциальную природу данных. Использовалась ради ортогональности предсказаний. Смешивание предсказаний CatBoost и слабой RNN v2 дало мощный синергетический эффект.

5. Анализ неудачных подходов

5.1. Отказ от Tweedie Loss

Тестирование специализированной функции потерь Tweedie (variance power 1.3–1.9) для zero-inflated распределений показало катастрофические результаты (RMSLE ≈ 2.76). Для метрики RMSLE логарифмическая трансформация таргета + стандартный RMSE остается безальтернативным решением.

5.2. Отказ от LightGBM

Архитектура leaf-wise нестабильна на сильно разреженных (zero-inflated) данных. Модель не способна корректно обрабатывать нулевые таргеты и была исключена.

5.3. Парадокс ортогональности ансамблей

Создание улучшенной версии **RNN v4** (окно 180 дней, шаг 14 дней) привело к тому, что новая RNN выучила те же паттерны, что и бустинг. Модели стали сильно скоррелированы (diversity уничтожен). Принято решение использовать для блендов только старую "слабую" нейросеть RNN v2.

6. Ожидающие отправки решения (План на день)

На основе проведенных локальных валидаций подготовлен пакет из 5 сабмитов, направленный на максимизацию результата через Seed Averaging и микро-тюнинг весов:

7. Стратегия: Жёсткое ансамблирование

Таблица 1: План финальных отправок

Имя файла	Суть эксперимента
catboost_v4a_seed_avg.csv	Соло-бустинг (5 seeds) для оценки базы.
blend_seed_avg_90_rnn10.csv	Основная ставка. СВ v4b (90%) + RNN v2 (10%).
blend_seed_avg_92_rnn8.csv	Микро-тюнинг (смещение в пользу бустинга).
blend_seed_avg_88_rnn12.csv	Микро-тюнинг (смещение в пользу нейросети).
blend_pseudo_90_rnn10.csv	Псевдо-разметка (Риск-ставка).

После оценки 5 запланированных сабмитов на Лидерборде, пайплайн будет переведен на стадию жесткого ансамблирования. Поиск идеальных весов (или построение мета-модели Stacking/Ridge) будет производиться автоматизированно через оптимизацию OOF-предсказаний на валидационном фолде.